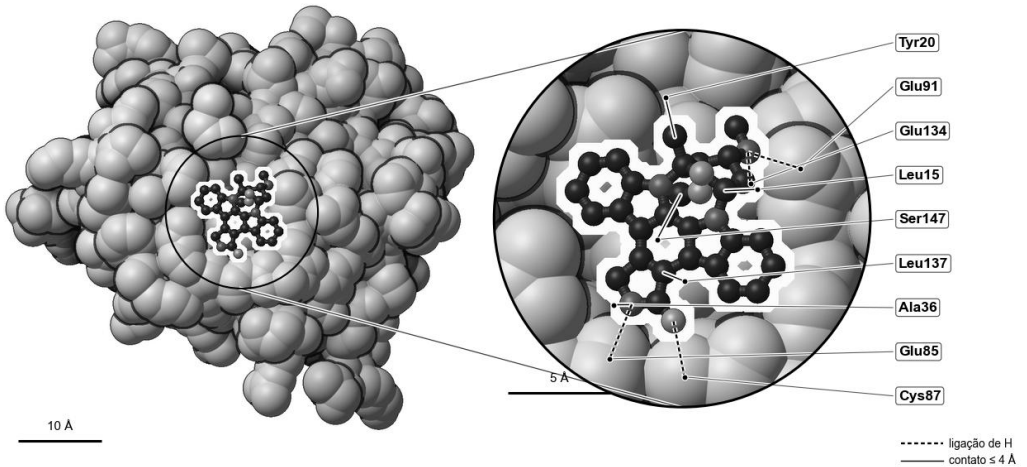
PREDIÇÃO DE PROPRIEDADES DE INTERAÇÕES ENTRE FÁRMACOS E RECEPTORES POR MEIO DE ALGORITMOS DE INTELIGÊNCIA ARTIFICIAL

Orientado(a): Margarita Chacon Romero*
Orientador(a): Dr.Willian Zalewski**
Coorientador(a): Dr.Joylan Nunes Maciel

*Bolsista IC (PRPPG-UNILA); E-mail: mc.romero.2020@aluno.unila.edu.br
** E-mail do Orientador: willian.zalewski@unila.edu.br
Grande Área do Conhecimento: Multidisciplinar
Sigla do Instituto: ILATIT



8ª SIEPE SEMANA INTEGRADA ENSINO | PESQUISA | EXTENSÃO
EICTI XV Encontro Anual de Iniciação Científica e XI Encontro de Iniciação em Desenvolvimento Tecnológico e Inovação
UNILA

SUMÁRIO

estrutura da apresentação

01 02 03 04 05 06 07 08

01 **Introdução** 3

02 **Objetivo** 4

03 **Justificativa** 5

04 **Método** 6–9

- Protocolo padronizado 7
- Preditores e combinação 8
- Análise estatística 9

05 **Resultados** 10–12

- Desempenho dos métodos 11
- Análise estatística 12

06 **Considerações finais** 13

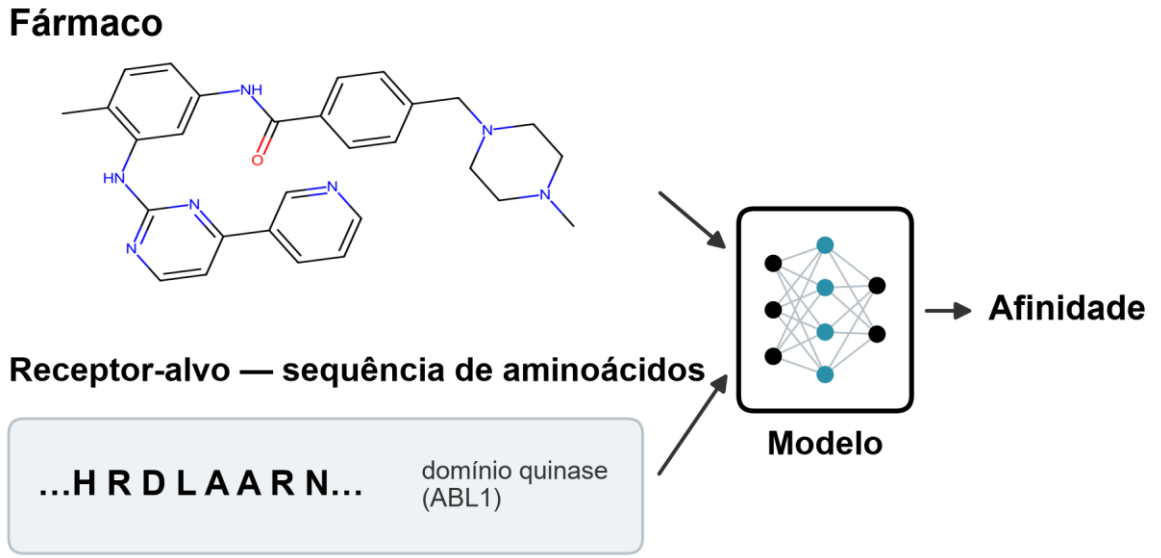
07 **Referências** 14

08 **Agradecimentos** 15

INTRODUÇÃO

- ✓ **Problema:** o desenvolvimento de fármacos exige longos ciclos de P&D e alto investimento;
- ✓ **Desafio:** os ensaios experimentais são a referência e demandam uma seleção criteriosa dos candidatos;
- ✓ **Aprendizado profundo:** estima a afinidade *in silico*, priorizando candidatos para validação experimental;
- ✓ **Lacuna:** arquiteturas heterogêneas, avaliadas sobre protocolos não padronizados.

Figura 1 – Predição da afinidade fármaco-alvo

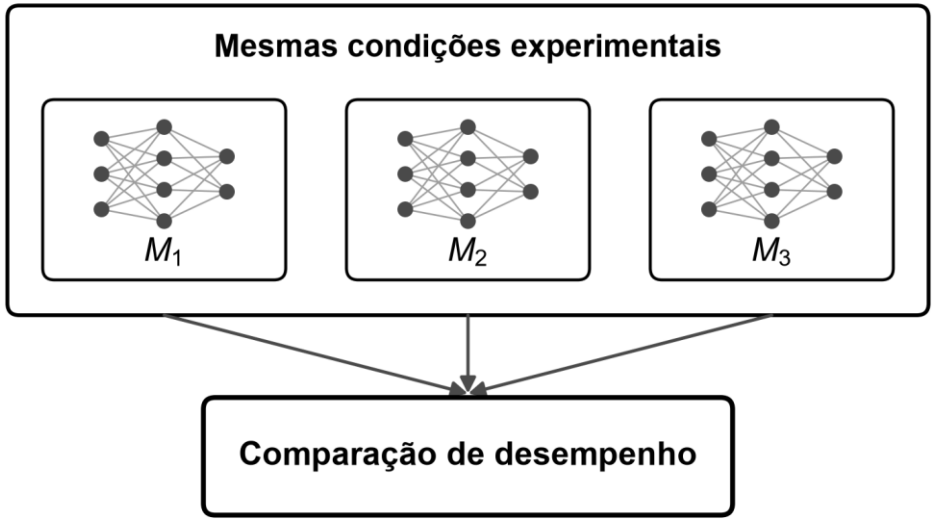


Fonte: O autor (2026). Estrutura gerada com RDKit.

OBJETIVO

Desenvolver e avaliar modelos de aprendizado de máquina para a predição de interações fármaco-alvo (DTI), a partir da revisão de métodos de ML existentes, comparando o desempenho de diferentes arquiteturas sob condições experimentais idênticas.

Figura 2 – Esquema de avaliação das arquiteturas



Fonte: O autor (2026).

JUSTIFICATIVA

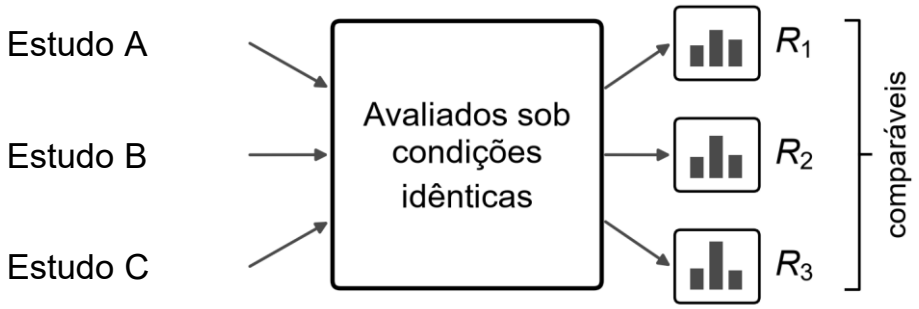
Na literatura, cada estudo usa bancos, representações e protocolos de validação distintos

Literatura

Estudo A	Banco X	Grafo	Hold-out
Estudo B	Banco Y	SMILES	10 folds
Estudo C	Banco Z	Subestrut.	3 folds

Resultados difíceis de comparar

Este trabalho



Comparação sob condições idênticas

MÉTODO

Como as arquiteturas foram avaliadas sob as mesmas condições

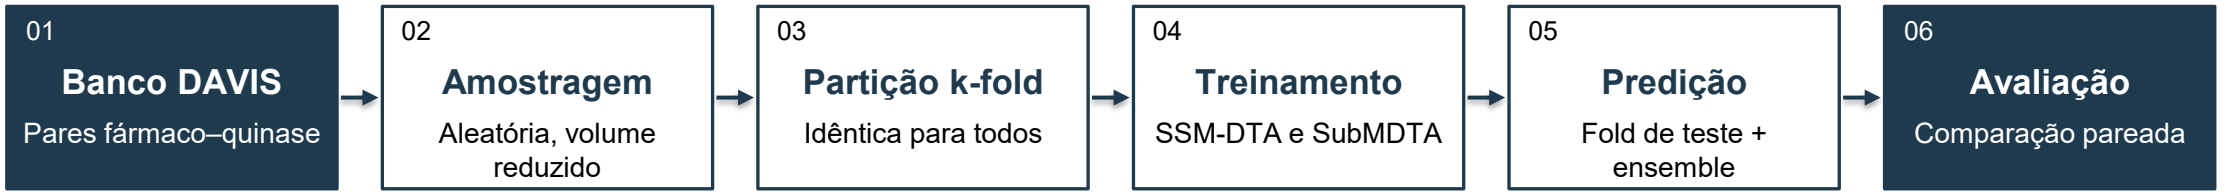
4.1 **Protocolo padronizado**
Dados, partição e treinamento

4.2 **Preditores e combinação**
Modelos avaliados e ensemble

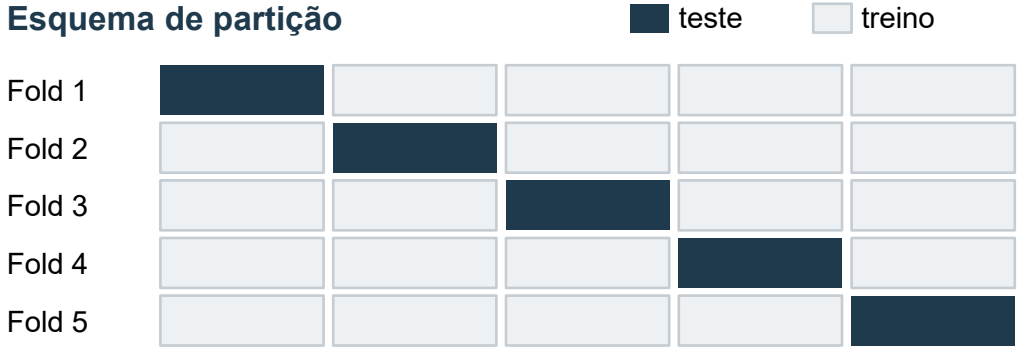
4.3 **Análise estatística**
Testes pareados e tamanho de efeito

MÉTODO: PROTOCOLO PADRONIZADO

Figura 4 – Fluxo do protocolo padronizado



Esquema de partição

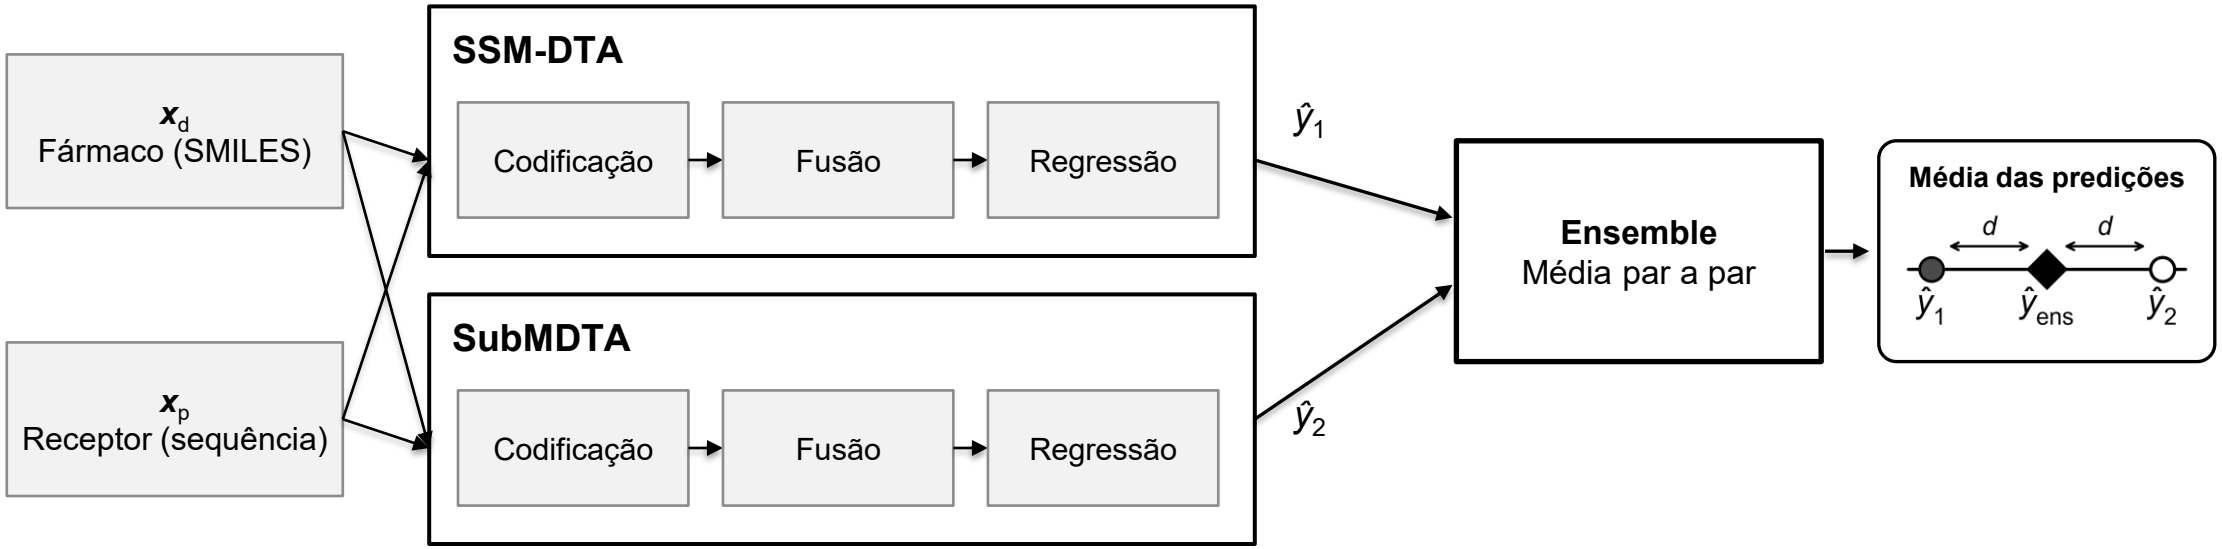


Elementos padronizados

Elemento	Configuração comum
Amostra	150 pares DTI, extraídos aleatoriamente
Validação cruzada	$k = 5$ (mesmas partições)
Épocas por fold	25
Ambiente	Python 3.7, execução local
Arquiteturas	Originais, sem alterações

MÉTODO: PREDITORES E COMBINAÇÃO

Figura 5 – Esquema dos preditores avaliados



Arquiteturas originais mantidas inalteradas; os blocos internos estão representados de forma genérica. $\hat{y}_1$: SSM-DTA; $\hat{y}_2$: SubMDTA.

Fonte: O autor (2026).

MÉTODO: ANÁLISE ESTATÍSTICA

Tabela 1 – Procedimentos estatísticos para a comparação pareada dos métodos (n = 5 folds)

Procedimento	Hipótese nula (H_0)	Estatística	Finalidade
Teste t pareado	$H_0: \ \mu_\Delta = 0$	$t = \frac{m_\Delta}{s_\Delta / \sqrt{n}}$	Comparar as médias de RMSE
Teste de Wilcoxon (postos sinalizados)	$H_0: \ \mathrm{Md}_\Delta = 0$	$W = \sum_{i=1}^{n} \mathrm{sgn}(\Delta_i)\, R_i$	Confirmação não paramétrica
d de Cohen (d_z)	—	$d_z = \frac{m_\Delta}{s_\Delta}$	Magnitude do efeito

Fonte: O autor (2026).

Nota: Δ = diferença de RMSE por fold; m_Δ e s_Δ = média e desvio padrão de Δ; α = 0,05. gl = n − 1. MdΔ = mediana de Δ; R_i = posto de $|\Delta_i|$. $|d_z|$: 0,2 pequena; 0,5 média; 0,8 grande.

Code availability

github.com/margarita316/Codigo-IA-

Desenvolvido com apoio do Claude (Anthropic)

RESULTADOS

O que a comparação padronizada revelou

5.1 **Desempenho dos métodos**

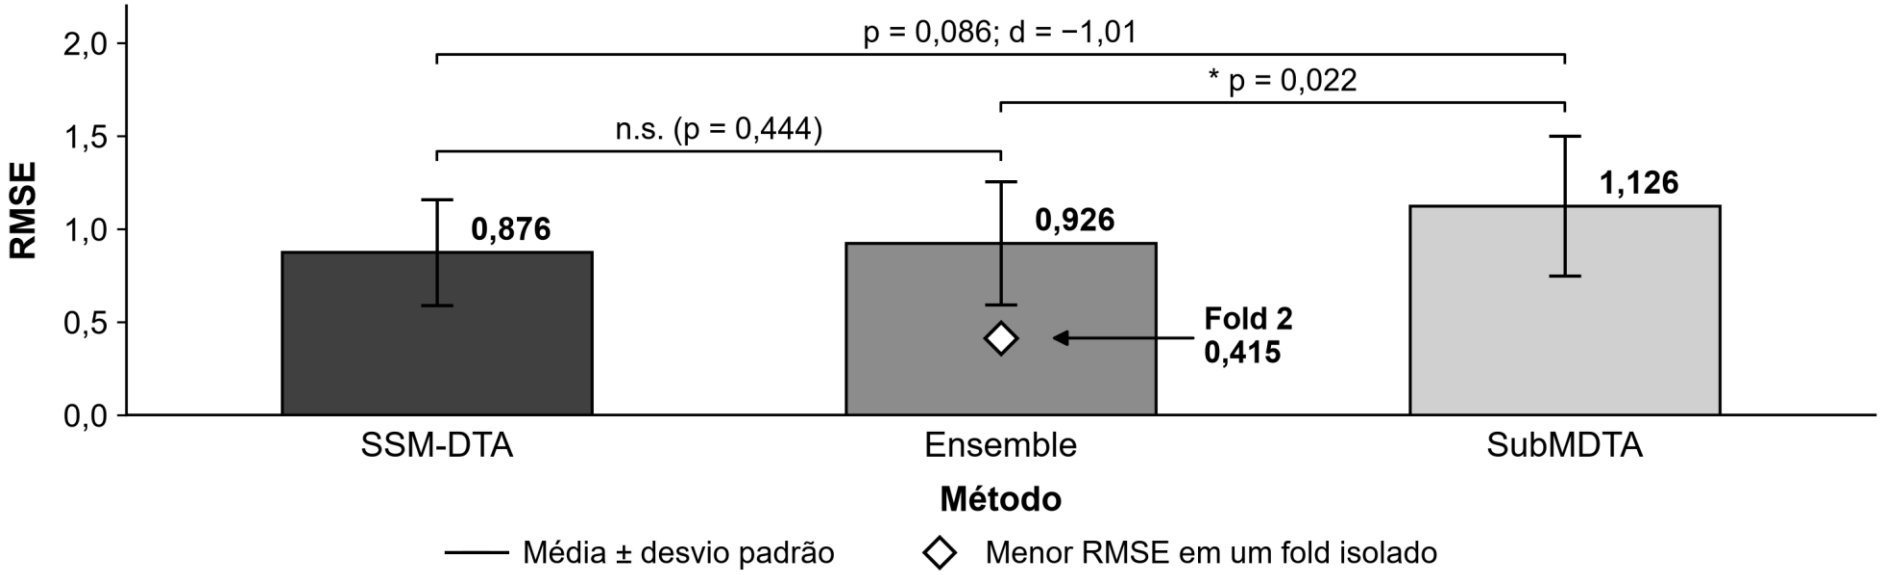
Erro médio sob o mesmo protocolo

5.2 **Análise estatística**

Diferenças, significância e efeito

RESULTADOS: DESEMPENHO DOS MÉTODOS

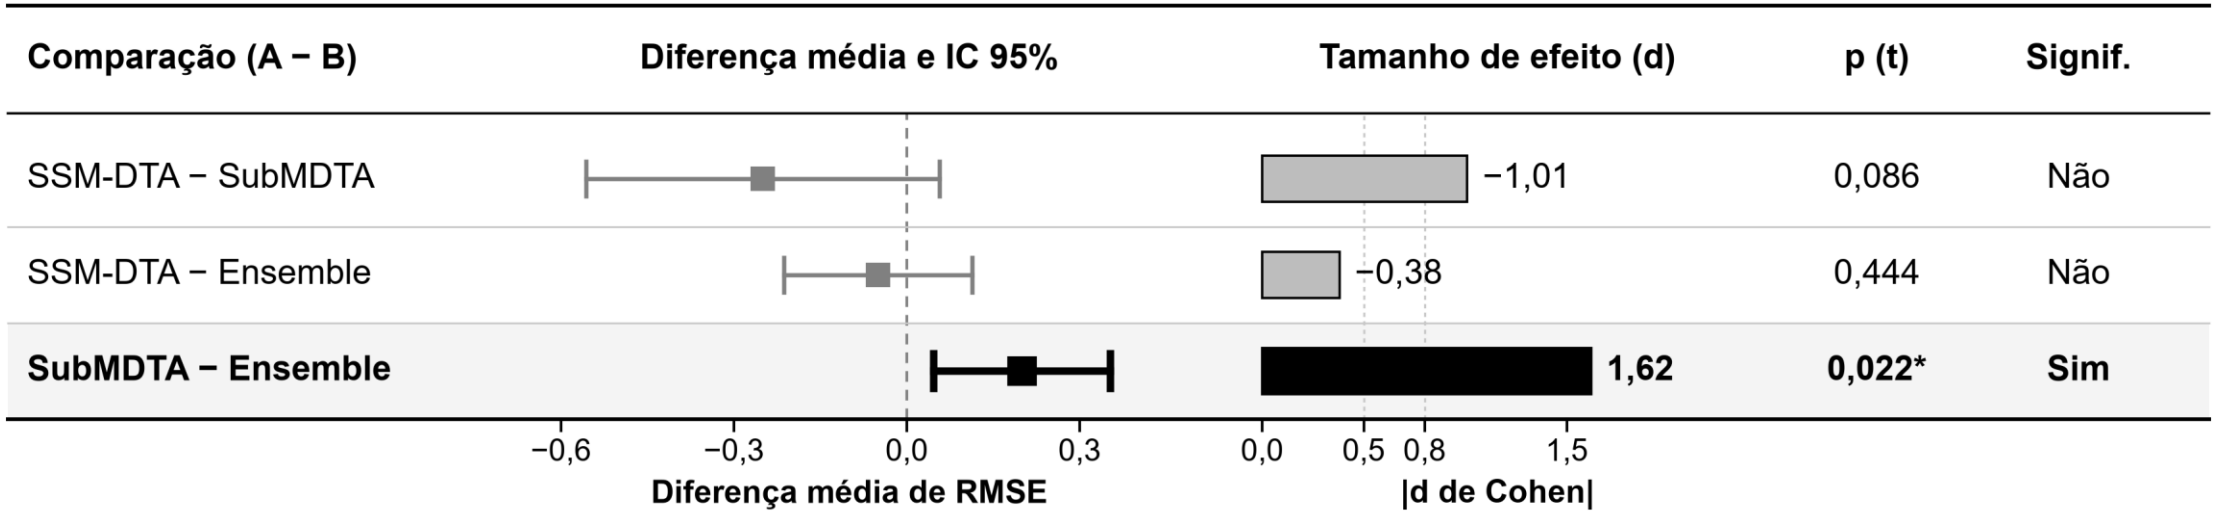
Gráfico 1 – RMSE médio ± desvio padrão por método nos 5 folds



Fonte: O autor (2026).
Nota: * p < 0,05 (teste t pareado); n.s.: não significativo; d: d de Cohen.

RESULTADOS: ANÁLISE ESTATÍSTICA

Gráfico 2 – Comparações pareadas de RMSE: diferença média, tamanho de efeito e significância

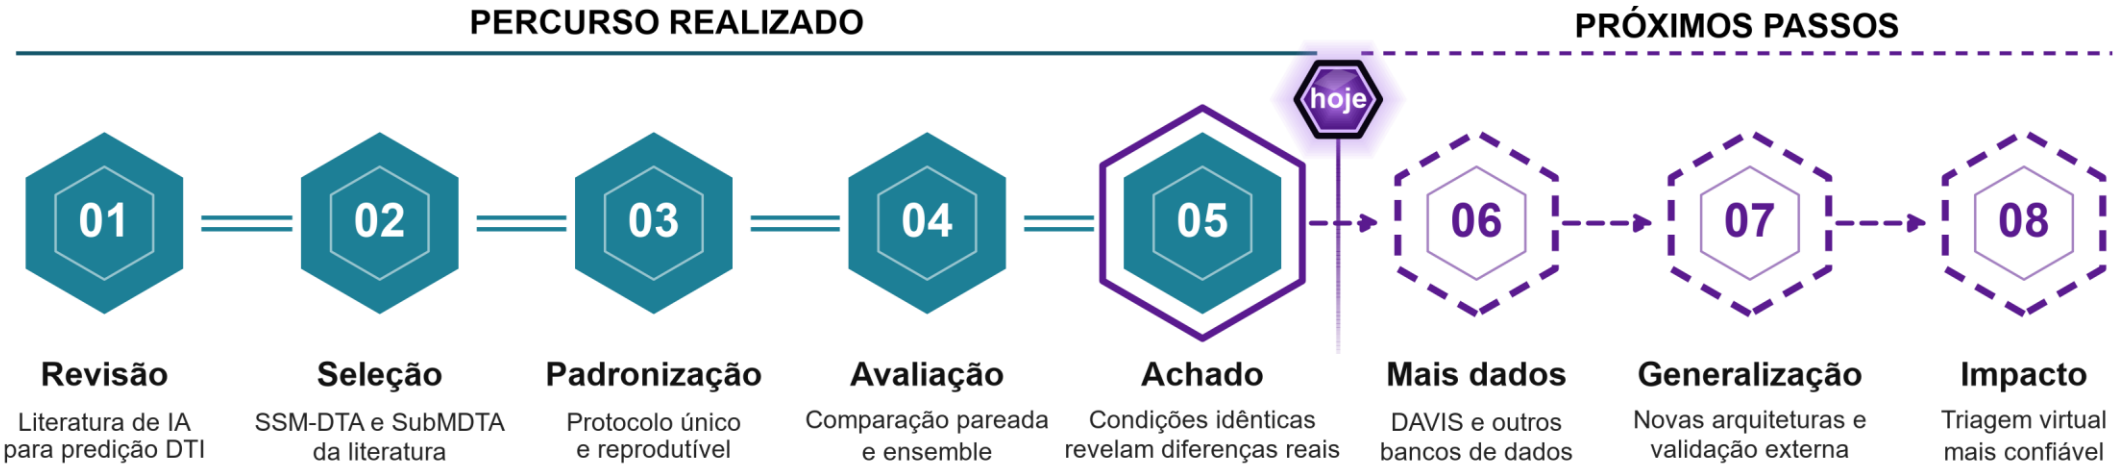


Fonte: O autor (2026).
Nota: IC 95% do teste t pareado (gl = 4); * p < 0,05.
Linhas pontilhadas: |d| = 0,5 (médio) e 0,8 (grande).

O Ensemble superou significativamente o SubMDTA; entre os demais pares, não houve diferença significativa.

CONSIDERAÇÕES FINAIS

Figura 6 – Trajetória do estudo e perspectivas futuras



Fonte: O autor (2026).

Avaliar com justiça é o primeiro passo para que a inteligência artificial acelere, com confiança, a descoberta de novos fármacos.

Terceiro e último trabalho da graduação: um ciclo que se encerra com gratidão — e um caminho que continua.

REFERÊNCIAS

[1] CHACON ROMERO, Margarita; MACIEL, Joylan Nunes; ZALEWSKI, Willian. Inteligência artificial para a predição de interações entre fármacos e receptores. In: SEMANA INTEGRADA DE ENSINO, PESQUISA E EXTENSÃO, 7., 2025, Foz do Iguaçu. *Anais [...]*. Foz do Iguaçu: UNILA, 2025. p. 132-133.

[2] CHACON ROMERO, Margarita. *Código IA*: códigos para predição de interações fármaco-receptor. [S. l.]: GitHub, 2026. Disponível em: github.com/margarita316/Codigo-IA- Acesso em: 14 out. 2026.

AGRADECIMENTOS

Agradeço ao professor Willian Zalewski, meu orientador, com quem tive a honra de trabalhar em três oportunidades distintas ao longo da minha trajetória acadêmica e a quem considero, com profundo respeito e admiração, um verdadeiro mentor na minha formação acadêmica, pela paciência, pelos ensinamentos e pela confiança depositada ao longo desse caminho, que me permitiram crescer e amadurecer diante dos próprios desafios, algo que levo comigo como um dos aprendizados mais valiosos desta etapa. Também agradeço à PRPPG-UNILA pelo apoio financeiro concedido por meio da bolsa de pesquisa, essencial para a continuidade e a conclusão deste trabalho.

UNILA PRPPG