MATERIAL DE APOIO

PREDIÇÃO DE PROPRIEDADES DE INTERAÇÕES ENTRE FÁRMACOS E RECEPTORES POR MEIO DE ALGORITMOS DE INTELIGÊNCIA ARTIFICIAL

Margarita Chacon Romero | Informações do relatório que não constam do resumo nem da apresentação

150
pares sorteados do DAVIS

5
folds de validação cruzada

3
preditores: SSM-DTA, SubMDTA e ensemble

25
épocas de treinamento

Slides 2 a 18
Pontos de consulta por assunto e respostas curtas

Slides 19 a 38
As 19 figuras do relatório, com a mesma numeração

Slides 39 a 61
Os 6 quadros e as 13 tabelas do relatório

Todos os números foram recalculados a partir das predições gravadas no repositório público.

APOIO: ROTEIRO DOS PONTOS

1. Dados e amostra
150 pares, censura em pKd = 5,0
Slides 3

2. Partição e treino
Folds, parâmetros e ambiente
Slides 4 e 5

3. Desempenho
Por fold e linhas de base
Slides 6

4. Melhor métrica
Valor e fold de cada método
Slides 7

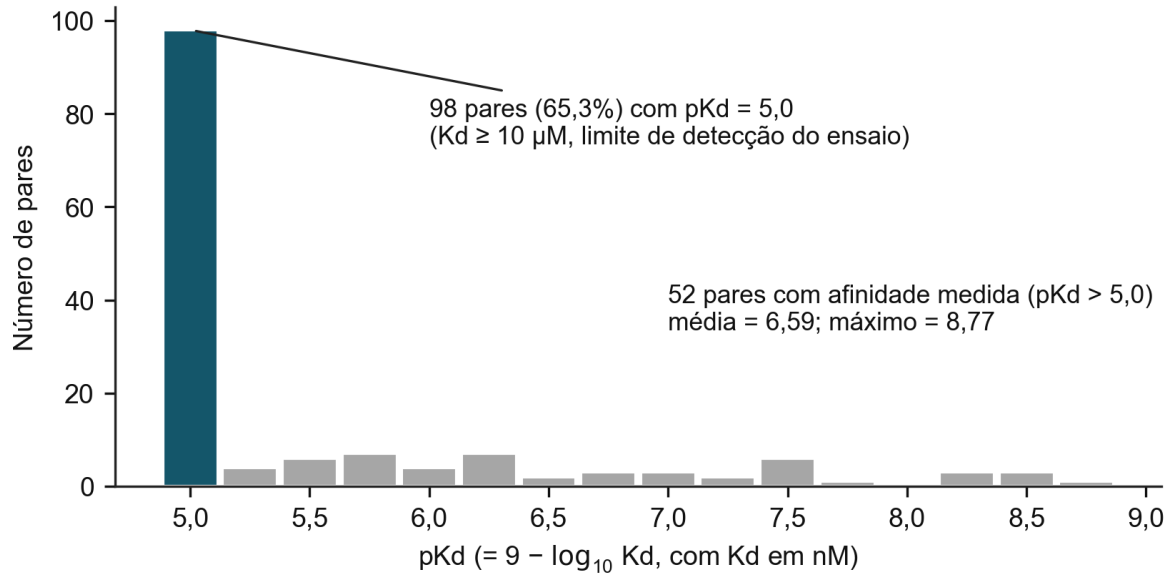
5. Estatística
Testes, correções e bootstrap
Slides 8 a 10

6. Ensemble
Por que não superou o SSM-DTA
Slides 11

7. Censura e dificuldade
Pares em 5,0 e folds
Slides 12 e 13

8. Limites e respostas
Conferência e perguntas
Slides 14 a 17

APOIO: DADOS E AMOSTRA



Fonte: O autor (2026), com dados do DAVIS (DAVIS et al., 2011).

- Arquivo do DAVIS: **25.772 pares** (68 fármacos e 379 proteínas).
- Amostra: **150 pares** sorteados ao acaso (semente 42), com 62 fármacos e 119 proteínas.
- pKd = 9 − $\log_{10}$(Kd em nM): quanto maior, mais forte a ligação.
- **98 pares (65,3%)** têm pKd = 5,0: Kd ≥ 10 μM, ou seja, sem ligação detectável (dado censurado). No arquivo completo são 71,2%.
- Só **52 pares** têm afinidade medida (média 6,59).

APOIO: PARTIÇÃO E COMPOSIÇÃO DOS FOLDS

Fold	Pares de teste	Pares com pKd = 5,0	pKd médio	pKd máximo
Fold 0	30	21 (70,0%)	5,53	8,55
Fold 1	30	20 (66,7%)	5,48	8,62
Fold 2	**30**	**23 (76,7%)**	**5,23**	**6,34**
Fold 3	30	16 (53,3%)	5,84	8,77
Fold 4	30	18 (60,0%)	5,68	8,37

- Cada fold: **108 pares de treino, 12 de validação e 30 de teste** (semente 42).
- Divisão **por pares**, e não por fármaco ou proteína inéditos.
- Mesmo assim, só **33%** dos pares de teste têm proteína vista no treino, contra **79%** com fármaco visto.
- O fold 2 é o mais fácil (76,7% em 5,0; pKd máximo 6,34), e o fold 3 é o mais difícil.

Fonte: O autor (2026), a partir do relatório.

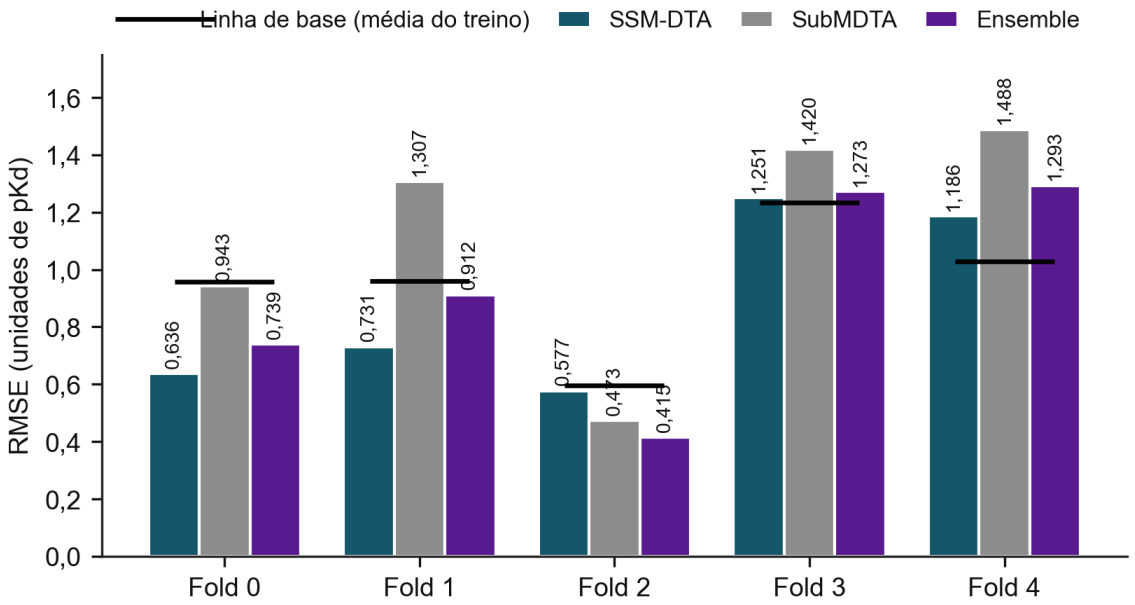
APOIO: TREINAMENTO E AMBIENTE

Parâmetro	SSM-DTA (variante de base)	SubMDTA
Épocas	25	25 (original: 1.200)
Taxa de aprendizado	5×10^{-5} (aquecimento e decaimento)	5×10^{-4}
Lote	1, acumulando 16	32
Atualizações	150 no total	cerca de 4 por época
Pré-treinamento	nenhum	GraphEnhance (sub_50000)
Escolha do ponto de parada	menor perda de validação	menor MSE de validação
Tempo	cerca de 19 min por fold	85 a 120 s por fold

Fonte: O autor (2026), a partir do relatório.

- **Equipamento:** Core i7-11800H, 7,8 GB de RAM e GPU RTX 3050 Ti de 4 GB.
- **Software:** Python 3.7, PyTorch 1.10.2 e fairseq 0.10.2.
- Arquiteturas **inalteradas**; hiperparâmetros **padrão** de cada código, sem ajuste.

APOIO: RMSE POR FOLD E LINHAS DE BASE



Fonte: O autor (2026), a partir do relatório.

- O SSM-DTA teve o menor RMSE em **4 dos 5 folds**; o ensemble, no fold 2.
- Nos folds 3 e 4, **nenhum método supera** a previsão da média do treino.
- Linhas de base (RMSE médio): média do treino **0,955**; valor constante 5,0 **1,065**.
- Frente à média do treino: SSM-DTA **−8,2%**, ensemble **−3,0%**, SubMDTA **+18,0%**.
- R^2 médio negativo nos três (−0,05; −0,52; −0,04).

APOIO: MELHOR MÉTRICA DE CADA MÉTODO

Métrica (melhor)	SSM-DTA	SubMDTA	Ensemble
RMSE (menor)	0,577 (fold 2)	0,473 (fold 2)	0,415 (fold 2)
MAE (menor)	0,536 (fold 2)	0,369 (fold 2)	0,343 (fold 2)
Pearson (maior)	0,793 (fold 0)	0,527 (fold 2)	0,705 (fold 0)
Spearman (maior)	0,540 (fold 1)	0,543 (fold 2)	0,579 (fold 0)
CI (maior)	0,780 (fold 1)	0,835 (fold 2)	0,830 (fold 2)
R^2 (maior)	0,557 (fold 0)	0,028 (fold 0)	0,403 (fold 0)

- O **melhor RMSE de todos ocorreu no fold 2**, o mais fácil.
- Nesse fold, prever sempre 5,0 já dá RMSE **0,491**, menor que o do SSM-DTA.
- Por isso, o melhor fold mostra o método em condição favorável. O desempenho esperado é a **média**: 0,876; 1,126; 0,926.
- Melhor Pearson: 0,793 (SSM-DTA) e 0,705 (ensemble), ambos no fold 0.

Fonte: O autor (2026), a partir do relatório.

APOIO: GLOSSÁRIO ESTATÍSTICO

Teste t pareado
Compara a média das diferenças de RMSE por fold com zero (4 graus de liberdade; t crítico 2,776).

Wilcoxon exato
Usa postos dos sinais, sem supor normalidade. Com 5 folds o menor p possível é 2/32 = 0,0625.

Permutação de sinais
Troca os sinais das 5 diferenças (32 combinações) e mede quão rara é a média observada.

d_z e g de Hedges
Tamanho do efeito: diferença média ÷ desvio das diferenças; g corrige amostra pequena. 0,2/0,5/0,8 = pequeno/médio/grande.

IC de 95%
Faixa plausível para a diferença verdadeira; se contém 0, não há significância a 5%.

Holm
Corrige o p por serem 3 comparações: o menor p é multiplicado por 3, o seguinte por 2, o último por 1.

Nadeau e Bengio
Corrige o t pela dependência entre folds (fator 1/5 + 30/120 = 0,45), que a média simples ignora.

Bootstrap dos pares
Reamostra os 150 pares 10.000 vezes. Supõe pares independentes, o que é otimista.

APOIO: RESULTADOS DOS TESTES PAREADOS

Comparação	Dif. média	IC de 95%	p (t)	p (Wilcoxon)	g	p Holm	p (Nadeau e Bengio)
SSM-DTA − SubMDTA	−0,250	[−0,556; 0,056]	0,086	0,1250	−0,81	0,172	0,206
SSM-DTA − Ensemble	−0,050	[−0,213; 0,113]	0,444	0,4375	−0,30	0,444	0,602
SubMDTA − Ensemble	**0,200**	**[0,047; 0,353]**	**0,022**	**0,0625**	**1,30**	**0,067**	**0,073**

- **SSM-DTA e SubMDTA:** efeito grande (g = −0,81), mas p = 0,086: tendência, sem significância formal.
- **SSM-DTA e ensemble:** sem evidência de diferença (p = 0,444).
- **Ensemble e SubMDTA:** melhor nos 5 folds (g = 1,30) e significativo no t (p = 0,022), mas **p = 0,067 após Holm**, 0,0625 no Wilcoxon exato e 0,073 após Nadeau e Bengio. Evidência moderada.

Fonte: O autor (2026). Diferença = RMSE do primeiro menos o do segundo; valores negativos favorecem o primeiro.

APOIO: VERIFICAÇÃO POR BOOTSTRAP

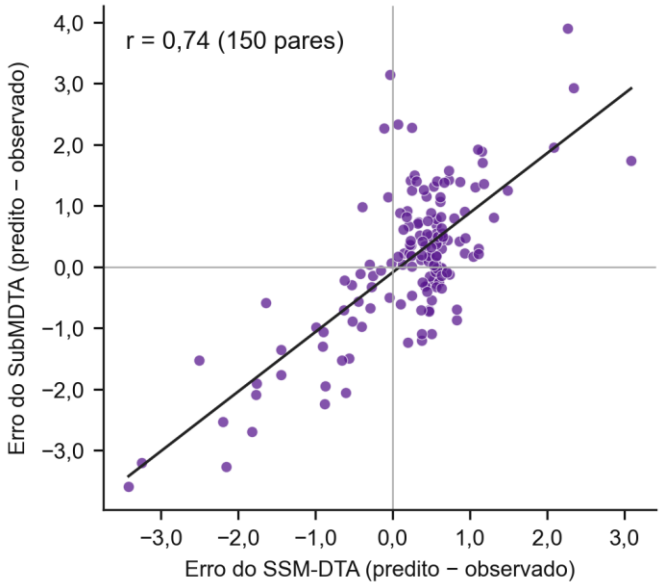
Comparação (150 pares)	Diferença de RMSE	IC percentil de 95%
SSM-DTA − SubMDTA	−0,266	[−0,392; −0,136]
SSM-DTA − Ensemble	−0,062	[−0,125; 0,001]
SubMDTA − Ensemble	0,203	[0,132; 0,275]

RMSE reunido (IC de 95%): SSM-DTA 0,77 a 1,08; SubMDTA 1,02 a 1,35; Ensemble 0,83 a 1,14.

- Os intervalos são **mais estreitos** do que os da análise por fold.
- O motivo: o bootstrap trata os 150 pares como independentes, mas fármacos e proteínas se repetem.
- A análise por fold tem só 5 unidades e **pouco poder**. Os dois enfoques concordam na direção e na ordem de grandeza (cerca de 0,25 entre SSM-DTA e SubMDTA).

Fonte: O autor (2026), a partir do relatório.

APOIO: O ENSEMBLE E O SSM-DTA



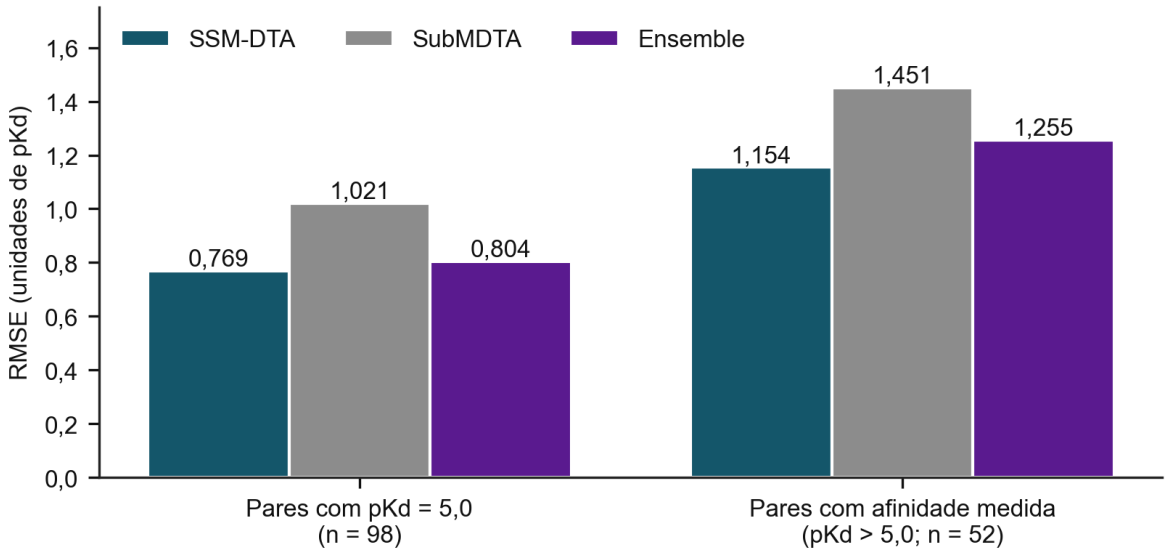
Fold	C	Limiar	Supera o melhor?
Fold 0	0,45	0,16	Não
Fold 1	0,54	−0,05	Não
Fold 2	**0,07**	**0,17**	**Sim**
Fold 3	1,45	1,34	Não
Fold 4	1,53	1,00	Não

C = média do produto dos erros; o ensemble vence se $C < (3 \cdot MSE_1 - MSE_2)/2$.

- Os erros dos dois métodos são **fortemente correlacionados** (r = 0,74).
- O SubMDTA é bem pior; com pesos iguais, a média só vence o melhor membro se a condição ao lado for cumprida: ocorreu **só no fold 2**.
- A média **sempre** reduz o erro frente à média dos dois (ambiguidade de 0,10 a 0,29).
- Peso exploratório ótimo: w = 0,89 (RMSE 0,872), quase igual ao SSM-DTA sozinho.

Fonte: O autor (2026), a partir do relatório.

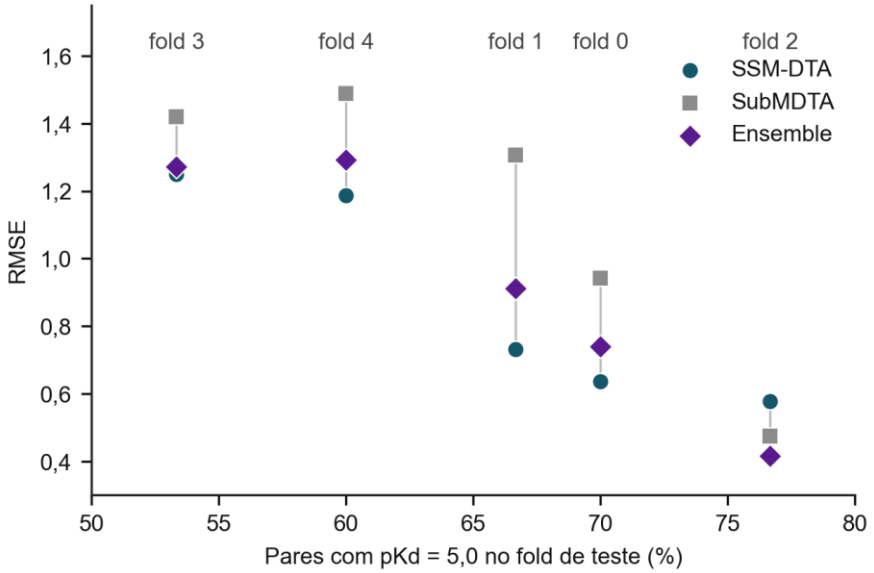
APOIO: PARES NO LIMITE DE DETECÇÃO



- RMSE é menor nos 98 pares em 5,0 (SSM-DTA 0,77) do que nos 52 medidos (1,15).
- Os modelos **superestimam** os pares em 5,0 (viés 0,61) e **subestimam** os medidos (−0,51): regressão à média.
- Correlação entre os pares medidos: SSM-DTA **0,35**, ensemble **0,22**, SubMDTA **0,06**.
- Na prática, o SubMDTA não ordenou os pares ativos nesta amostra.

Fonte: O autor (2026), a partir do relatório.

APOIO: DIFICULDADE DOS FOLDS



Método	Proteína vista (n = 50)	Proteína inédita (n = 100)
SSM-DTA	0,720	1,007
SubMDTA	1,043	1,254
Ensemble	0,776	1,073

- Quanto mais pares em 5,0 no teste, menor o RMSE: correlação de postos **−1,00** (SSM-DTA) e **−0,90** (SubMDTA e ensemble), com 5 folds.
- O erro é menor quando a proteína aparece no treino. Análise descritiva, sem teste.

Fonte: O autor (2026), a partir do relatório.

APOIO: LIMITAÇÕES DO ESTUDO

Amostra
150 pares (0,6% do banco); muitas proteínas aparecem uma única vez.

Folds
Apenas 5: pouco poder; Wilcoxon com p mínimo de 0,0625.

Dependência
Folds compartilham treino e pares compartilham fármacos e alvos.

Treino curto
25 épocas, hiperparâmetros sem ajuste e SSM-DTA sem pré-treinamento.

Validação
O ponto de parada é escolhido com só 12 pares.

Censura
Mais de 65% dos pares em 5,0, tratados como valores exatos.

Determinismo
Treino em GPU sem semente determinística: predições podem variar um pouco.

Ponderação
A curva de pesos do ensemble foi feita no teste: é ilustrativa.

8ª SIEPE SEMANA INTEGRADA ENSINO | PESQUISA | EXTENSÃO
EICTI XV Encontro Anual de Iniciação Científica e XI Encontro de Iniciação em Desenvolvimento Tecnológico e Inovação
UNILA

APOIO: CONFERÊNCIA COM O RESUMO SUBMETIDO

Valor	Resumo submetido	Relatório
RMSE SSM-DTA	0,876 ± 0,285	0,876 ± 0,284
RMSE SubMDTA	1,126 ± 0,377	1,126 ± 0,377
RMSE ensemble	0,926 ± 0,332	0,926 ± 0,332
Sub × Ens: p (t); d	0,022; 1,62	0,022; 1,62
Melhor RMSE do ensemble (fold 2)	0,415	0,415

- Os valores coincidem; a diferença de 0,285 e 0,284 é de **arredondamento** (o resumo usou RMSE já arredondados).
- O relatório acrescenta as ressalvas sobre o ensemble (Holm, Wilcoxon exato, Nadeau e Bengio).
- **Não se pode afirmar:** que o SSM-DTA seja superior em geral, que o SubMDTA seja pior como arquitetura, nem o desempenho com dados completos ou divisões por alvo inédito.

Fonte: O autor (2026), a partir do relatório.

APOIO: RESPOSTAS RÁPIDAS (1 DE 2)

Por que só 150 pares?

Para rodar 3 preditores em 5 folds em um notebook com GPU de 4 GB. A amostra é aleatória (semente 42) e mantém a maioria de pares em 5,0.

Por que 25 épocas?

Mesmo orçamento para os dois métodos. Os originais usam muito mais (SubMDTA: 1.200 épocas), e por isso os resultados valem para treino curto.

Houve ajuste de hiperparâmetros?

Não. Foram usados os valores padrão de cada código, com as arquiteturas inalteradas.

Por que a variante de base do SSM-DTA?

Ela não usa o pré-treinamento por linguagem mascarada nem dados sem rótulo, que não foram empregados neste estudo.

A divisão é por alvo inédito?

Não, é por pares. Ainda assim, 67% dos pares de teste têm proteína inédita e 79% têm fármaco já visto.

O melhor fold é o desempenho do método?

Não. O fold 2 é o mais fácil. O desempenho esperado é a média dos 5 folds.

APOIO: RESPOSTAS RÁPIDAS (2 DE 2)

O ensemble é melhor que o SubMDTA?
Nos 5 folds sim (g = 1,30) e p = 0,022 no t, mas p = 0,067 após Holm e mínimo de 0,0625 no Wilcoxon.

Por que o ensemble não bateu o SSM-DTA?
Erros muito correlacionados (r = 0,74) e SubMDTA bem pior: a condição da média só foi cumprida no fold 2.

Por que RMSE como métrica principal?
Está em unidades de pKd e pesa mais os erros grandes. É complementada por MAE, Pearson, Spearman, CI e R^2.

O que significa pKd = 5,0?
Kd ≥ 10 μM: o ensaio não detectou ligação. É dado censurado, tratado como valor exato na prática do DAVIS.

O SubMDTA é pior como arquitetura?
Não se pode concluir. Aqui ele teve 108 pares e 25 épocas, bem abaixo do treino para o qual foi concebido.

O estudo é reprodutível?
Sim. Scripts, partições, predições e métricas estão no repositório público; as métricas se recalculam sem treinar.

APOIO: REFERÊNCIAS PRINCIPAIS

PEI, Q. et al. Breaking the barriers of data scarcity in drug-target affinity prediction. Briefings in Bioinformatics, v. 24, n. 6, 2023.
PAN, S. et al. SubMDTA: drug target affinity prediction based on substructure extraction and multi-scale features. BMC Bioinformatics, v. 24, 2023.
DAVIS, M. I. et al. Comprehensive analysis of kinase inhibitor selectivity. Nature Biotechnology, v. 29, n. 11, p. 1046-1051, 2011.
TANG, J. et al. Making sense of large-scale kinase inhibitor bioactivity data sets. J. Chem. Inf. Model., v. 54, n. 3, p. 735-743, 2014.
PAHIKKALA, T. et al. Toward more realistic drug-target interaction predictions. Briefings in Bioinformatics, v. 16, n. 2, p. 325-337, 2015.
KROGH, A.; VEDELSBY, J. Neural network ensembles, cross validation, and active learning. NIPS, v. 7, p. 231-238, 1995.
NADEAU, C.; BENGIO, Y. Inference for the generalization error. Machine Learning, v. 52, n. 3, p. 239-281, 2003.
HOLM, S. A simple sequentially rejective multiple test procedure. Scand. J. Statistics, v. 6, n. 2, p. 65-70, 1979.
WILCOXON, F. Individual comparisons by ranking methods. Biometrics Bulletin, v. 1, n. 6, p. 80-83, 1945.
CHACON ROMERO, M. Código IA. GitHub, 2026. Disponível em: https://github.com/margarita316/Codigo-IA-.

8ª SIEPE SEMANA INTEGRADA ENSINO | PESQUISA | EXTENSÃO
EICTI XV Encontro Anual de Iniciação Científica e XI Encontro de Iniciação em Desenvolvimento Tecnológico e Inovação
UNILA

FIGURAS, QUADROS E TABELAS

Reprodução do relatório

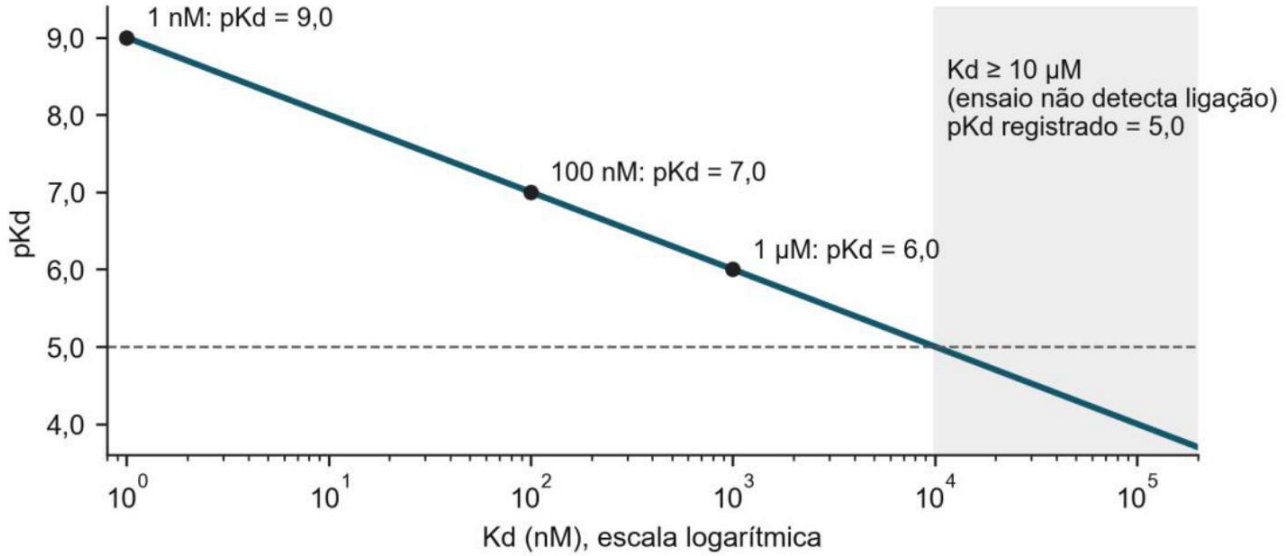
Cada figura, quadro e tabela aparece tal como no relatório: mesma numeração, mesmo título e mesma fonte

19	6	13
Figuras (slides 20 a 38)	Quadros (slides 39 a 44)	Tabelas (slides 45 a 61)

A melhor métrica de cada método, com o fold em que ocorreu, está na Tabela 4 (slide 48).

RELATÓRIO: FIGURA 1

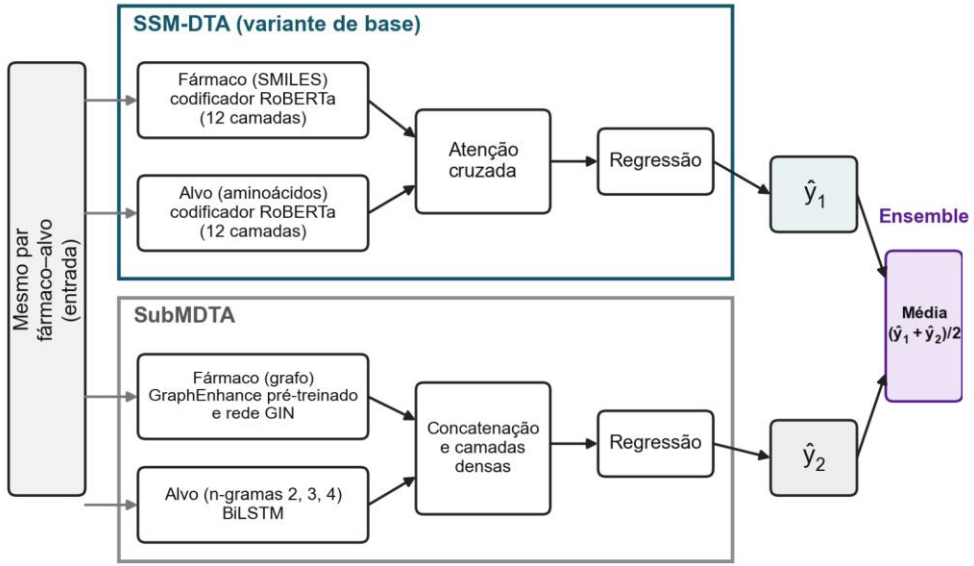
Figura 1 – Relação entre a constante de dissociação (Kd) e o pKd



Fonte: O autor (2026), a partir da Equação 1.

RELATÓRIO: FIGURA 2

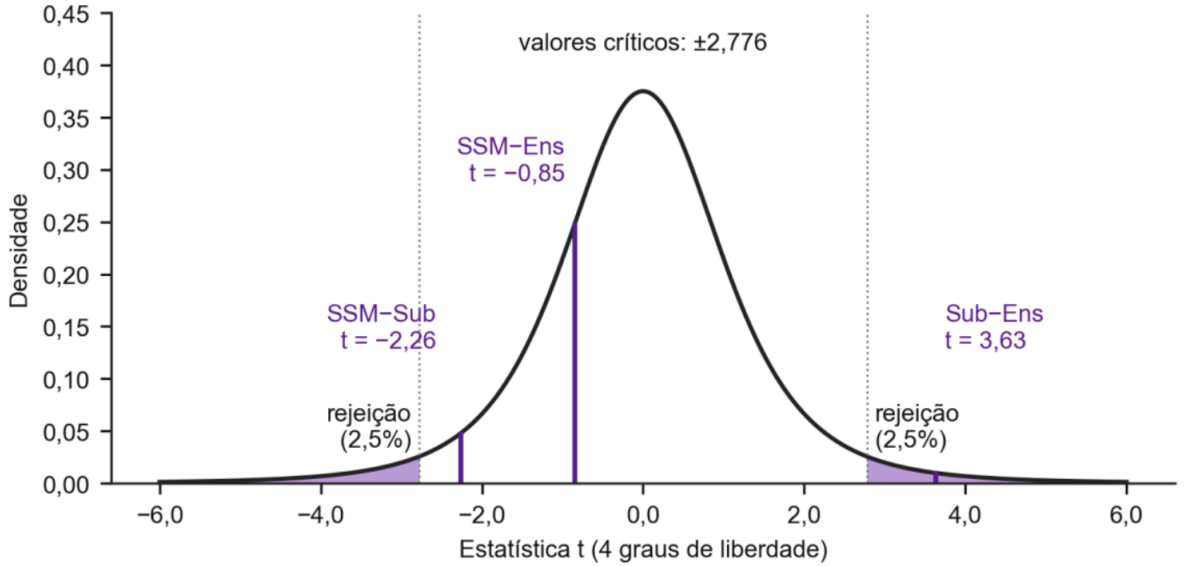
Figura 2 – Esquema dos preditores avaliados e do ensemble



Fonte: O autor (2026).

RELATÓRIO: FIGURA 3

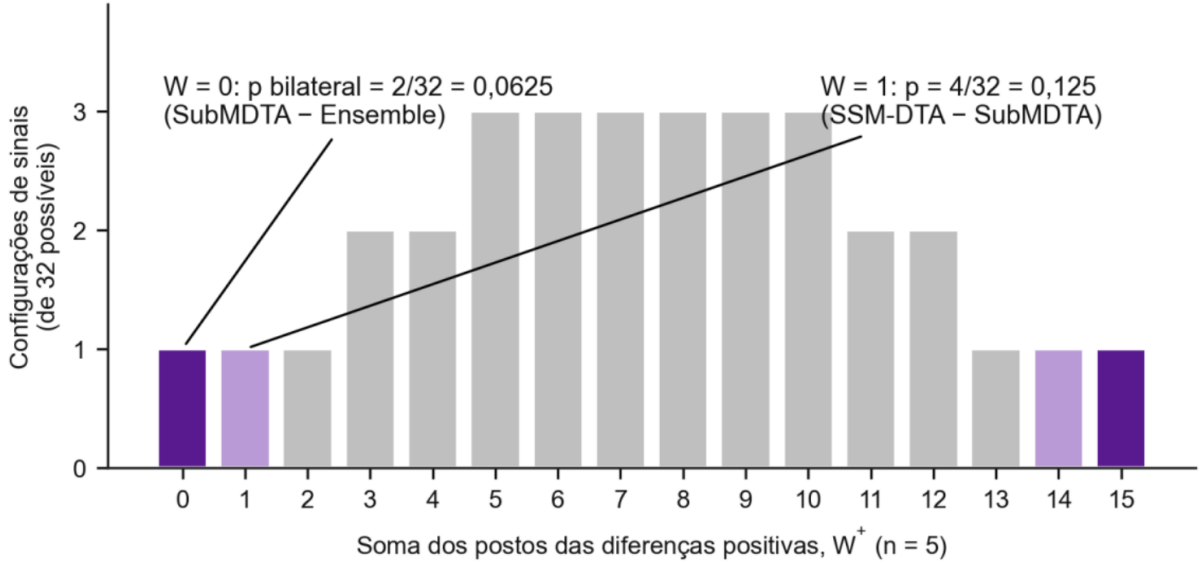
Figura 3 – Distribuição t de Student com 4 graus de liberdade e estatísticas observadas



Fonte: O autor (2026), a partir dos resultados da seção 4.5.

RELATÓRIO: FIGURA 4

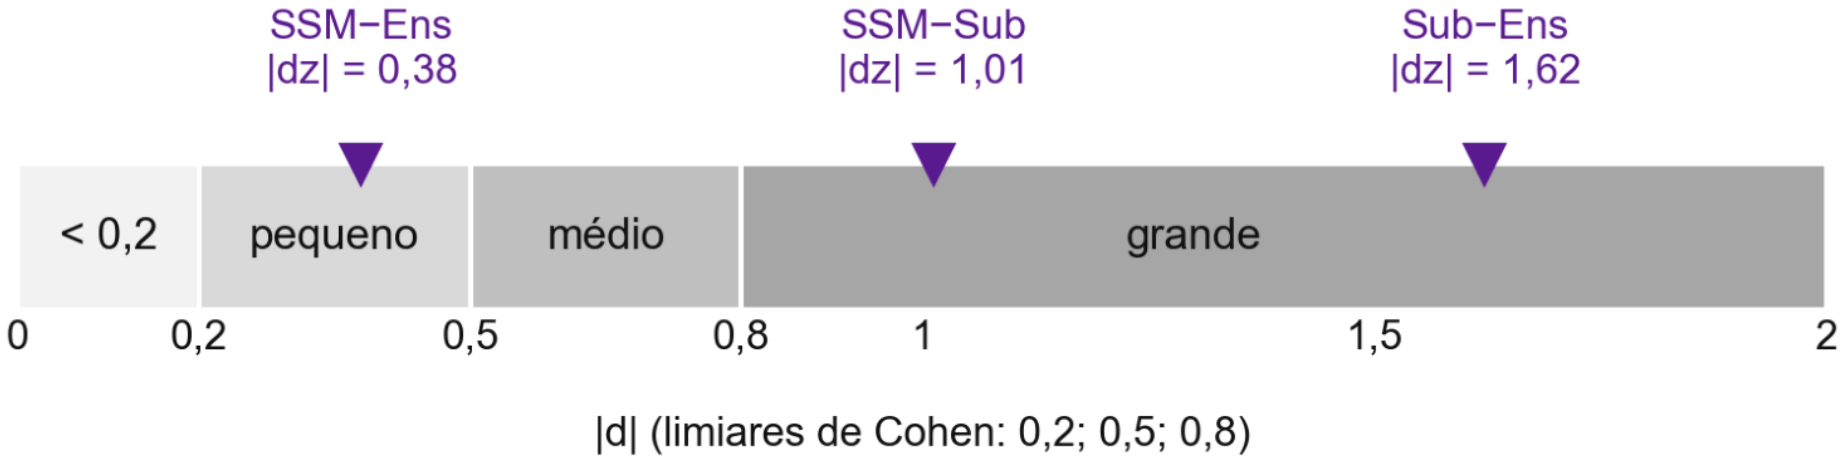
Figura 4 – Distribuição exata da soma de postos W^+ do teste de Wilcoxon para n = 5



Fonte: O autor (2026), por enumeração das 32 combinações de sinais.

RELATÓRIO: FIGURA 5

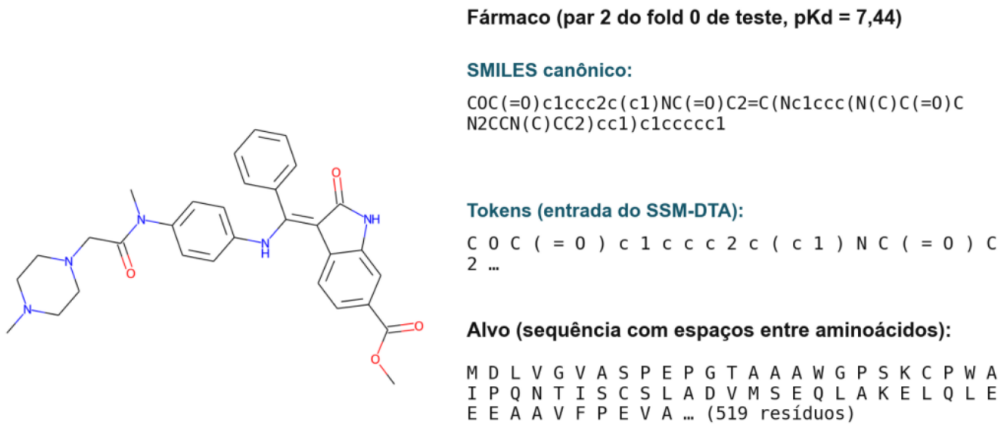
Figura 5 – Escala de interpretação do tamanho de efeito e valores observados de $|d_z|$



Fonte: O autor (2026), com os limiares de Cohen (1988).

RELATÓRIO: FIGURA 6

Figura 6 – Exemplo de entrada: estrutura do fármaco, SMILES canônico, símbolos e sequência do alvo



Fonte: O autor (2026), com a estrutura desenhada pelo RDKit a partir de um par do conjunto de teste da partição 0.

RELATÓRIO: FIGURA 7

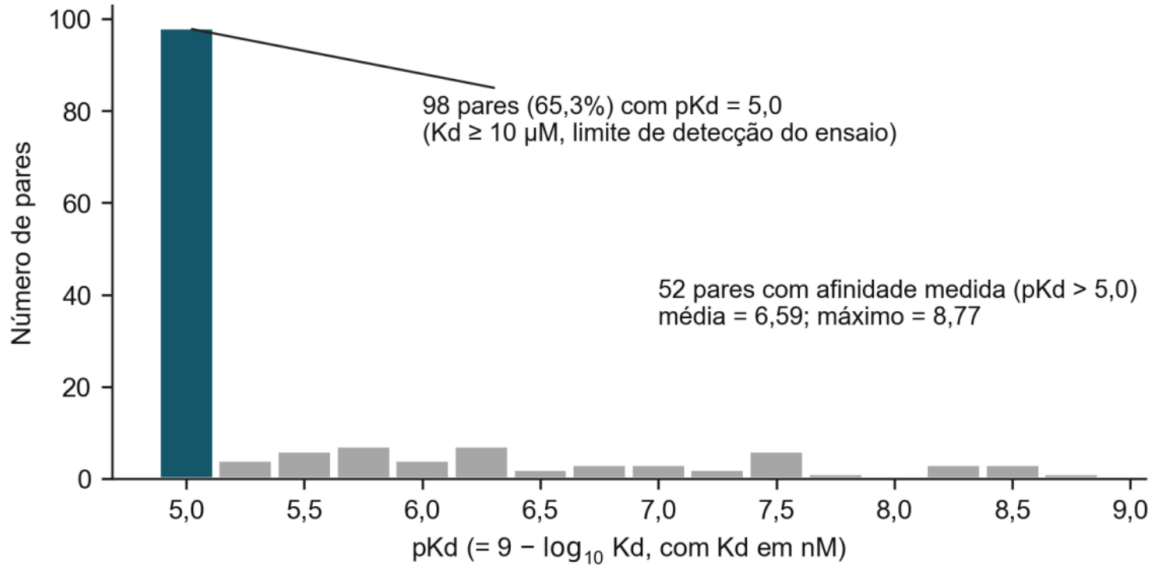
Figura 7 – Esquema de partição em cinco folds, com 108 pares de treino, 12 de validação e 30 de teste por fold



Fonte: O autor (2026).

RELATÓRIO: FIGURA 8

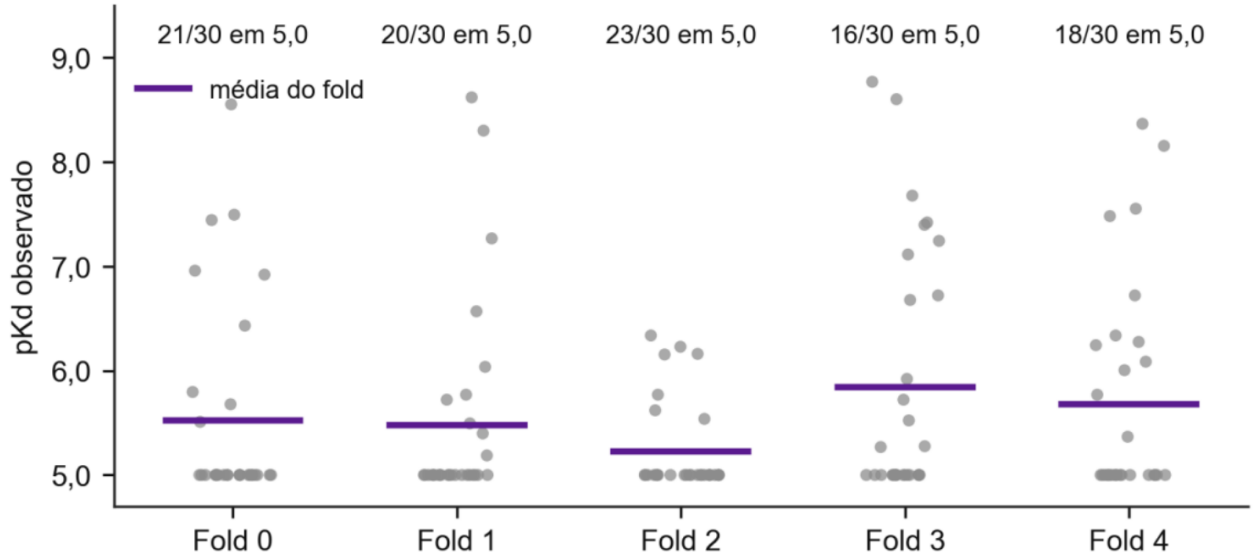
Figura 8 – Distribuição dos valores de pKd dos 150 pares da amostra



Fonte: O autor (2026), com dados do DAVIS (DAVIS et al., 2011).

RELATÓRIO: FIGURA 9

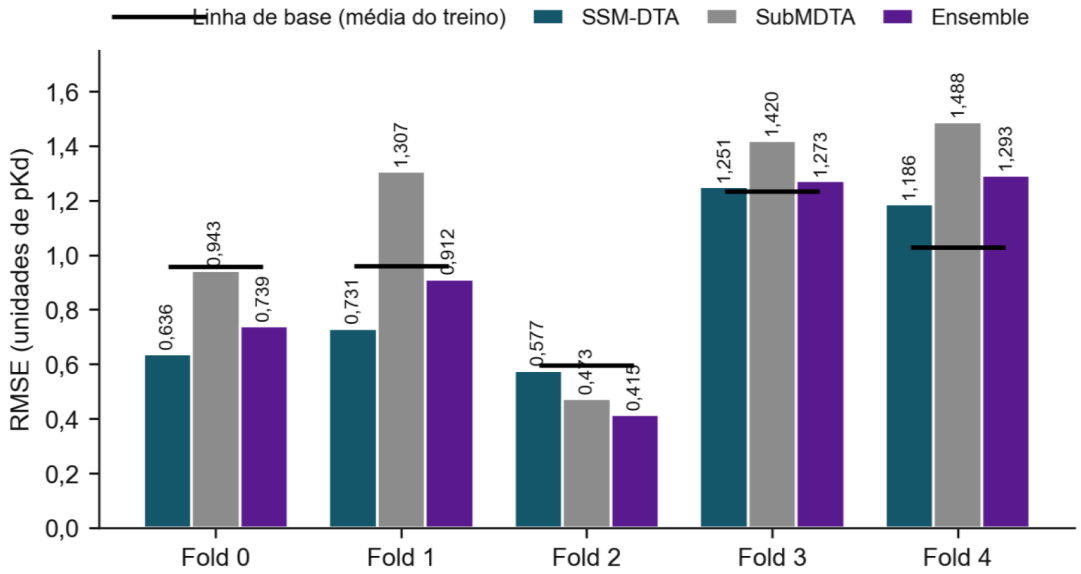
Figura 9 – Valores de pKd observados nos conjuntos de teste de cada fold



Fonte: O autor (2026).

RELATÓRIO: FIGURA 10

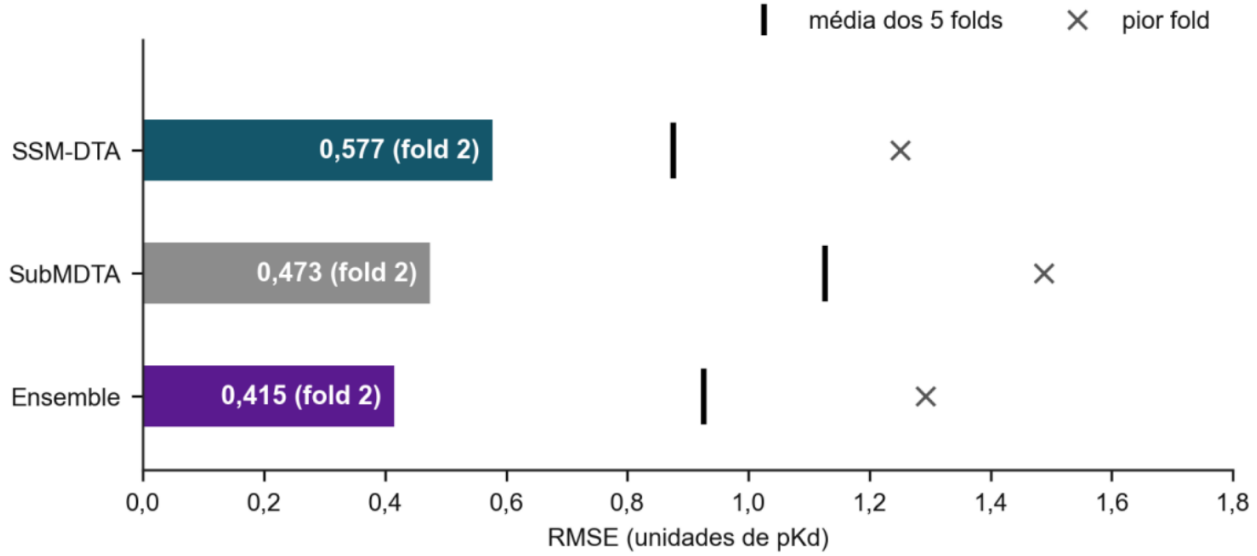
Figura 10 – RMSE de cada método em cada fold e linha de base da média do treino



Fonte: O autor (2026).

RELATÓRIO: FIGURA 11

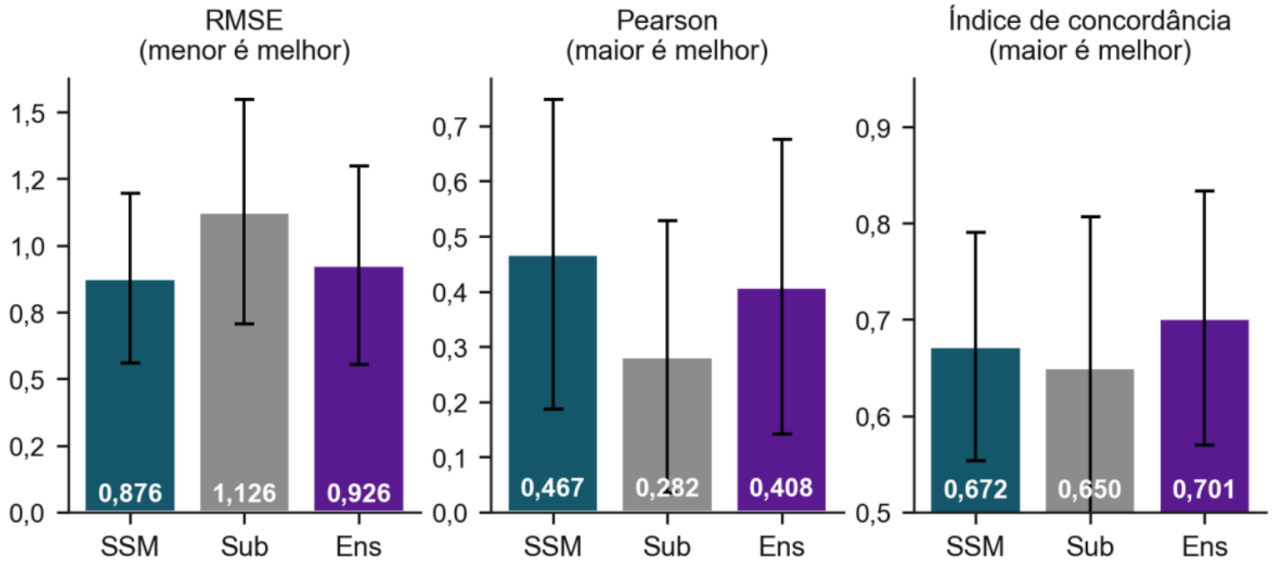
Figura 11 – Melhor RMSE de cada método, com a partição, a média e o pior valor



Fonte: O autor (2026).

RELATÓRIO: FIGURA 12

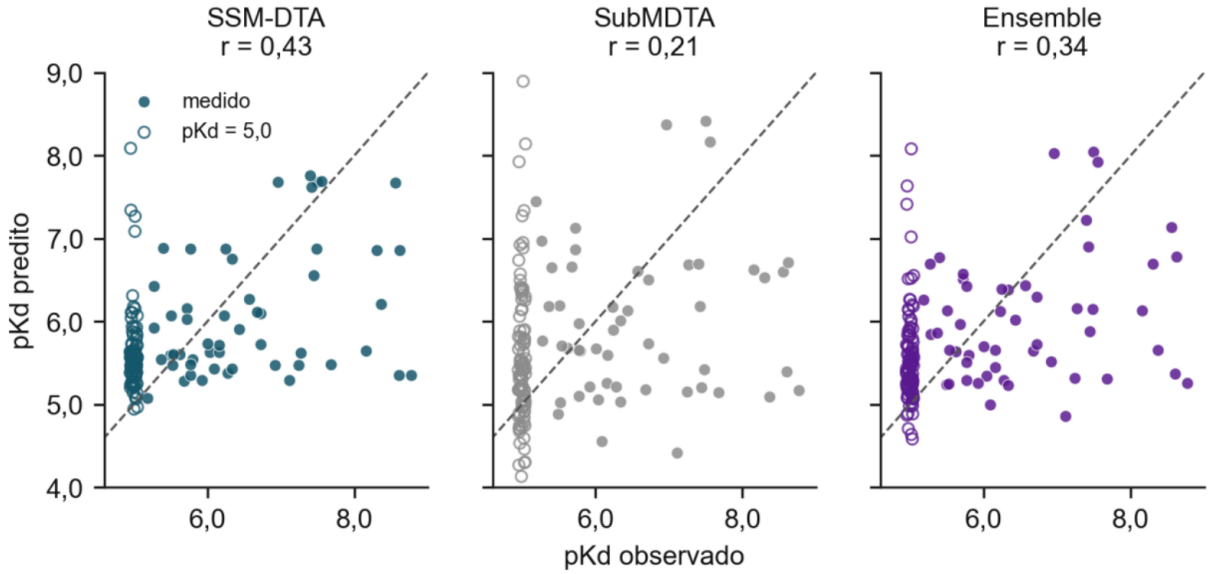
Figura 12 – RMSE, correlação de Pearson e índice de concordância médios de cada método



Fonte: O autor (2026).

RELATÓRIO: FIGURA 13

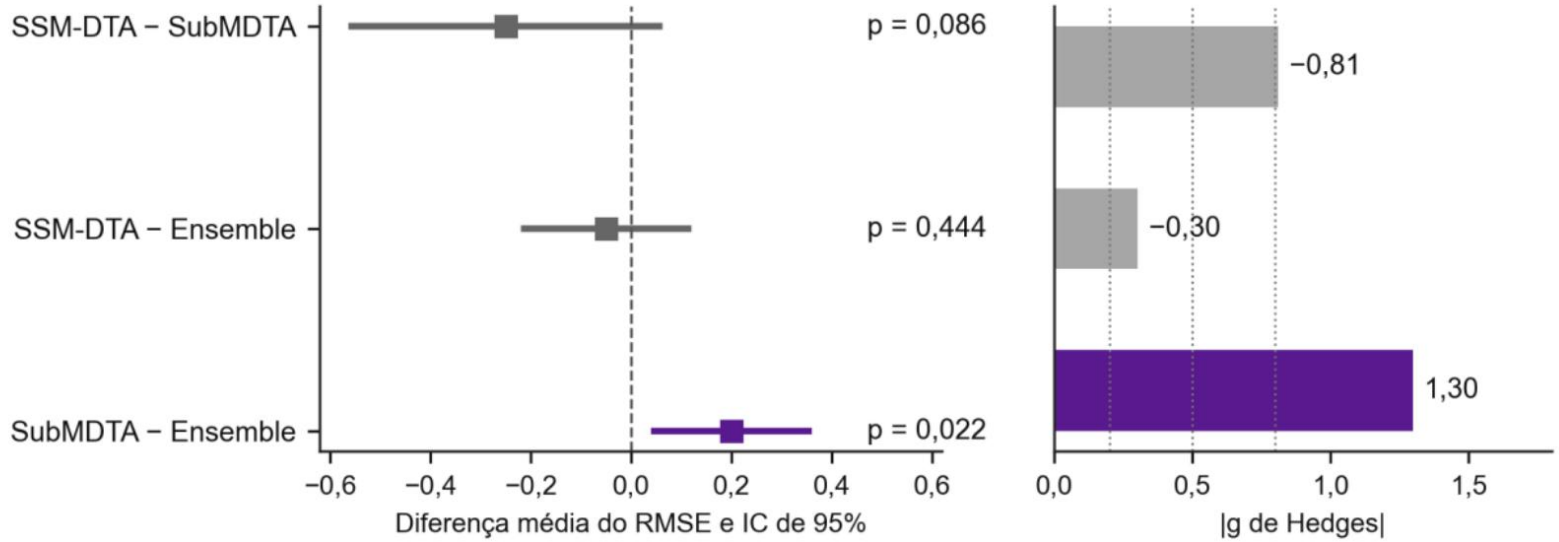
Figura 13 – Valores de pKd preditos e observados nos 150 pares de teste



Fonte: O autor (2026).

RELATÓRIO: FIGURA 14

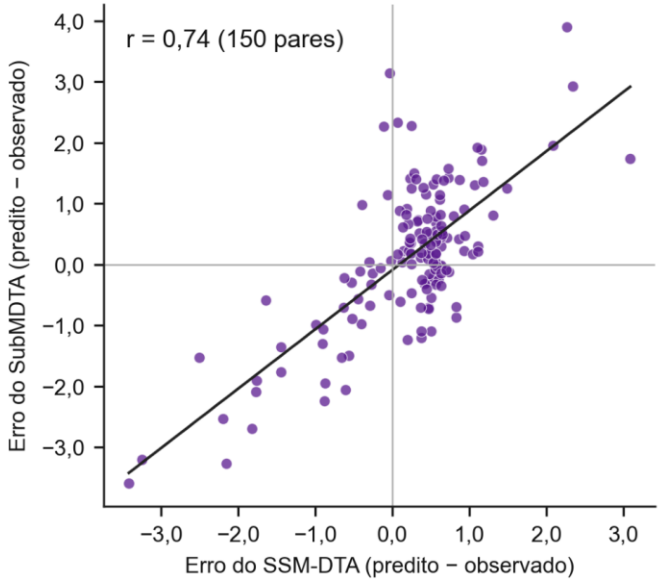
Figura 14 – Intervalos de confiança de 95% da diferença de RMSE e tamanho de efeito (g de Hedges)



Fonte: O autor (2026).

RELATÓRIO: FIGURA 15

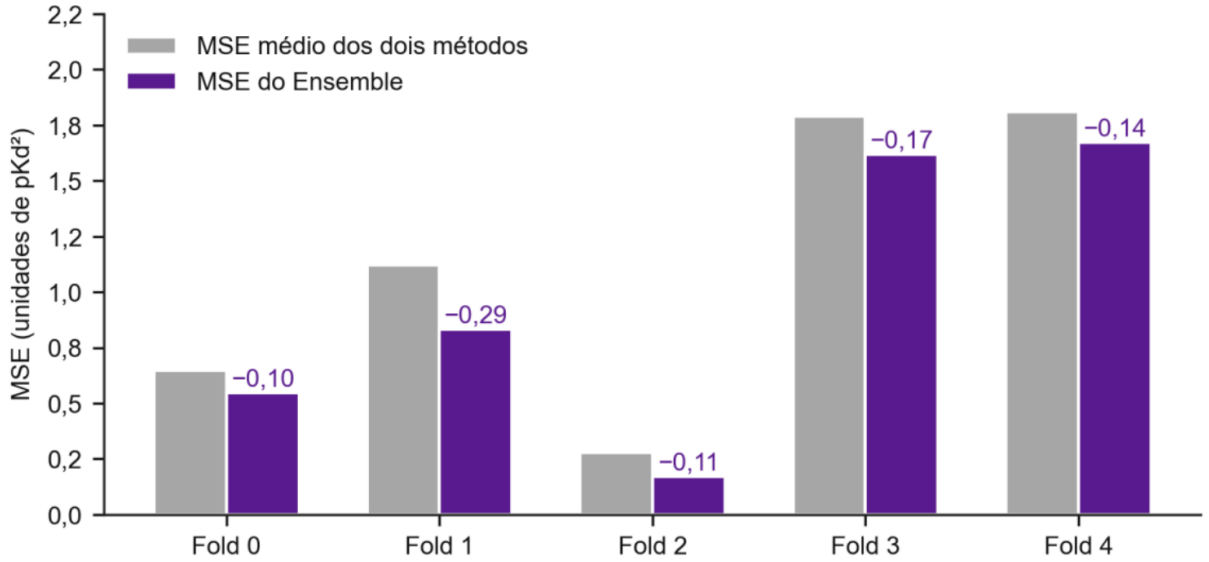
Figura 15 – Erro do SubMDTA em função do erro do SSM-DTA nos 150 pares de teste



Fonte: O autor (2026).

RELATÓRIO: FIGURA 16

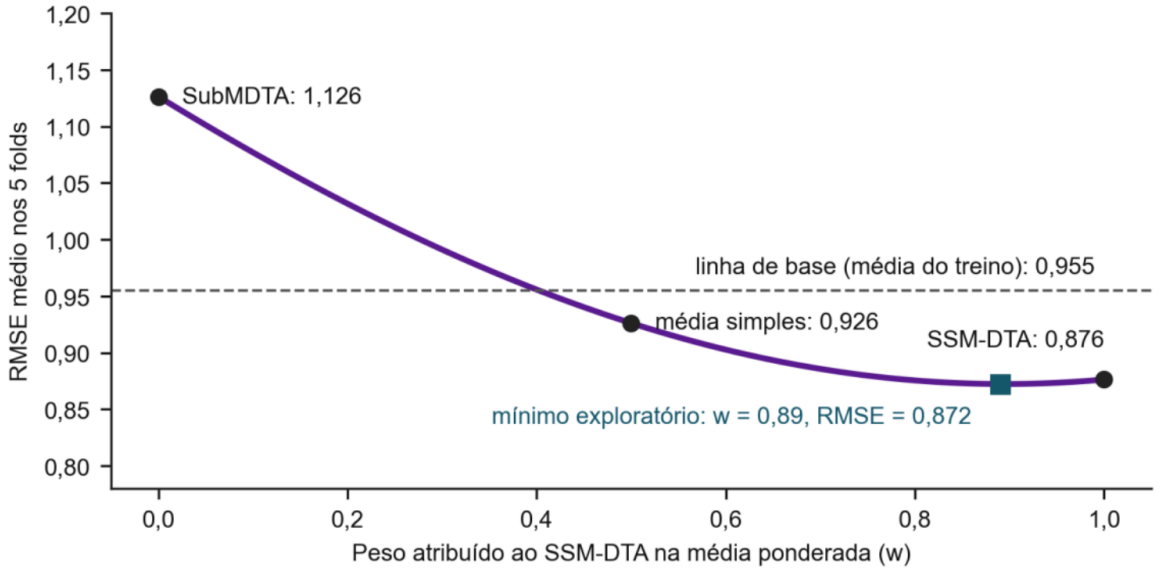
Figura 16 – Erro quadrático médio do ensemble e média dos erros dos dois métodos, por fold



Fonte: O autor (2026). Os valores sobre as barras roxas indicam a ambiguidade (redução do erro).

RELATÓRIO: FIGURA 17

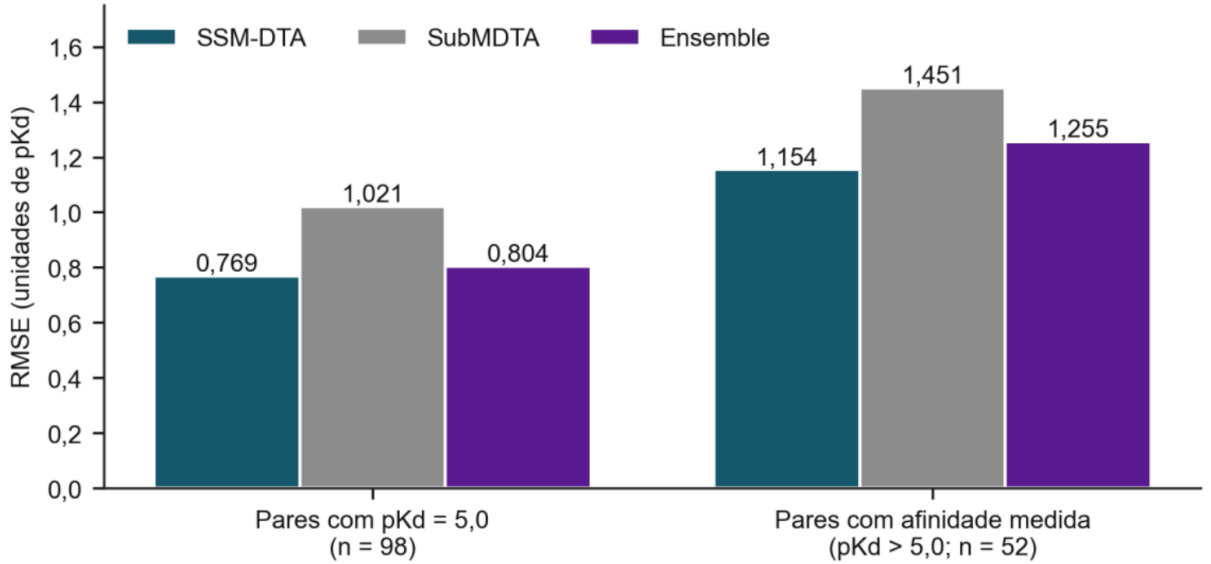
Figura 17 – RMSE médio em função do peso atribuído ao SSM-DTA na média ponderada



Fonte: O autor (2026). Análise exploratória, calculada nos conjuntos de teste.

RELATÓRIO: FIGURA 18

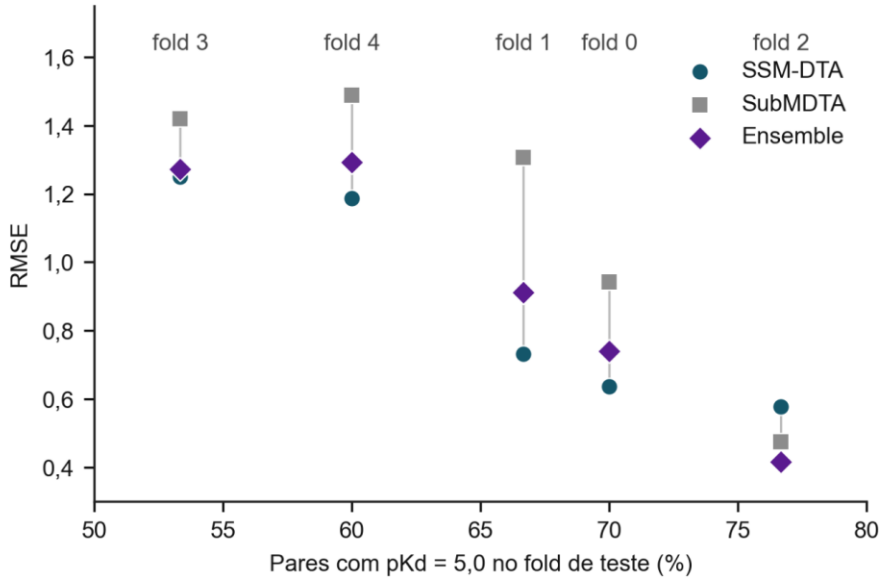
Figura 18 – RMSE nos pares com pKd = 5,0 e nos pares com afinidade medida



Fonte: O autor (2026).

RELATÓRIO: FIGURA 19

Figura 19 – RMSE de cada método em função da proporção de pares com pKd = 5,0 no teste do fold



Fonte: O autor (2026).

RELATÓRIO: QUADRO 1

Quadro 1 – Comparação entre os métodos avaliados

Característica	SSM-DTA (variante de base)	SubMDTA
Representação do fármaco	SMILES canônico, dividido em símbolos (tokens)	Grafo molecular com vetor de 78 características por átomo
Representação do alvo	Sequência de aminoácidos	Sequência de aminoácidos, em n-gramas de 2, 3 e 4
Codificador do fármaco	RoBERTa de 12 camadas	GraphEnhance pré-treinado e rede de isomorfismo de grafos
Codificador do alvo	RoBERTa de 12 camadas	Redes BiLSTM
Interação fármaco-alvo	Atenção cruzada	Concatenação e camadas densas
Pré-treinamento usado	Nenhum (variante de base)	Ponto de verificação do GraphEnhance fornecido pelos autores
Função de perda	Erro quadrático médio (regressão)	Erro quadrático médio
Referência	Pei et al. (2023)	Pan et al. (2023)

Fonte: O autor (2026).

8ª SIEPE SEMANA INTEGRADA ENSINO | PESQUISA | EXTENSÃO
EICTI XV Encontro Anual de Iniciação Científica e XI Encontro de Iniciação em Desenvolvimento Tecnológico e Inovação
UNILA

RELATÓRIO: QUADRO 2

Quadro 2 – Métricas de desempenho utilizadas

Métrica	O que mede	Faixa	Melhor valor	Observação
RMSE	Magnitude típica do erro, com peso maior para erros grandes	0 a ∞	Menor	Métrica principal; em unidades de pKd
MAE	Magnitude média absoluta do erro	0 a ∞	Menor	Menos sensível a erros extremos
Pearson (r)	Associação linear entre predito e observado	−1 a 1	Maior	Ignora erro sistemático constante
Spearman (ρ)	Associação monótona entre os postos	−1 a 1	Maior	Menos sensível a valores extremos
CI	Proporção de pares ordenados corretamente	0 a 1	Maior	0,5 equivale ao acaso
R^2	Ganho em relação a prever a média do teste	−∞ a 1	Maior	Negativo indica pior do que a média

Fonte: O autor (2026).

RELATÓRIO: QUADRO 3

Quadro 3 – Resumo dos procedimentos estatísticos

Procedimento	Finalidade	Pressupostos principais	Limitação neste estudo
Teste t pareado	Comparar a média das diferenças com zero	Diferenças aproximadamente normais; independência	Normalidade não verificável com n = 5; partições dependentes
Teste t corrigido (Nadeau e Bengio)	Compensar a dependência entre partições	Os mesmos do teste t	Correção aproximada
Shapiro-Wilk	Verificar a normalidade das diferenças	Amostra aleatória	Poder muito baixo com n = 5
Wilcoxon	Comparar sem supor normalidade	Simetria das diferenças	Valor-p mínimo de 0,0625 com n = 5
Permutação de sinais	Teste exato baseado nos valores	Permutabilidade dos sinais sob H_0	Apenas 32 combinações
d_z e g de Hedges	Medir a magnitude da diferença	Nenhum para o cálculo	Limiares são convenções
Intervalo de confiança de 95%	Estimar a faixa da diferença verdadeira	Os do teste t	Largo com n = 5
Holm e Bonferroni	Controlar o erro entre as três comparações	Nenhum além dos testes usados	Reduz o poder
Bootstrap dos pares	Estimar a incerteza sobre os 150 pares	Pares independentes	Pares compartilham fármacos e alvos

Fonte: O autor (2026).

RELATÓRIO: QUADRO 4

Quadro 4 – Parâmetros de treinamento de cada método

Parâmetro	SSM-DTA (variante de base)	SubMDTA
Épocas	25	25 (original: 1.200)
Otimizador	Adam ($\beta = 0,9; 0,98; \varepsilon = 10^{-6}$)	Adam
Taxa de aprendizado	5×10^{-5}, com aquecimento de 15 atualizações e decaimento polinomial	5×10^{-4}, constante
Lote	1, com acumulação de 16 (lote efetivo de 16)	32
Atualizações no total	150 (6 por época)	Cerca de 4 por época (108 pares em lotes de 32), em 25 épocas
Regularização	Decaimento de pesos 0,1; dropout 0,1; recorte de gradiente 1,0	Padrão do código original
Função de perda	Erro quadrático médio	Erro quadrático médio
Seleção do ponto de parada	Menor perda de validação	Menor erro quadrático médio de validação
Pré-treinamento	Nenhum	GraphEnhance (*sub_50000*)
Tempo de execução	Cerca de 45 s por época; cerca de 19 min por fold	85 a 120 s por fold; 470 s no total

Fonte: O autor (2026).

RELATÓRIO: QUADRO 5

Quadro 5 – Ambiente computacional utilizado

Item	Especificação
Equipamento	Computador portátil com processador Intel Core i7-11800H (2,30 GHz)
Memória	7,8 GB de memória RAM
Placa gráfica	NVIDIA GeForce RTX 3050 Ti Laptop, com 4 GB
Sistema operacional	Windows 11
Linguagem e bibliotecas	Python 3.7; PyTorch 1.10.2; fairseq 0.10.2; PyTorch Geometric 2.0.4; torch-sparse 0.6.12; RDKit; scikit-learn; NumPy; SciPy

Fonte: O autor (2026).

RELATÓRIO: QUADRO 6

Quadro 6 – Organização da pasta do estudo no repositório

Pasta ou arquivo	Conteúdo
README.md	Resumo do estudo, resultados por fold e instruções de reprodução
documentos/	Resumo submetido ao EICTI 2026 e apresentação, em PDF
codigo/01_preparacao_dados/	Script de preparação dos dados e das cinco partições
codigo/02_ssm_dta/	Scripts de treinamento por fold e de extração das predições do SSM-DTA
codigo/03_submdta/	Script de validação cruzada do SubMDTA nas mesmas partições
codigo/04_ensemble_e_estatistica/	Scripts do ensemble, das métricas por fold e da análise estatística
codigo/05_figuras/	Scripts das figuras de resultados
dados/davis150_folds/	Partições (treino, validação e teste) dos 150 pares
resultados/	Predições por fold, métricas em JSON e figuras

Fonte: O autor (2026).

RELATÓRIO: TABELA 1

Tabela 1 – Comparação entre o arquivo completo do DAVIS e a amostra utilizada

Característica	**Arquivo completo**	**Amostra (150 pares)**
Pares	25.772	150
Fármacos distintos	68	62
Proteínas distintas	379	119
Pares com pKd = 5,0 (Kd ≥ 10 μM)	71,2% (18.343)	65,3% (98)
pKd mínimo	5,00	5,00
pKd máximo	10,80	8,77
pKd médio ± desvio padrão	5,41 ± 0,83	5,55 ± 0,97

Fonte: O autor (2026).

RELATÓRIO: TABELA 2

Tabela 2 – Composição dos conjuntos de teste de cada fold

Fold	Pares de teste	Pares com pKd = 5,0	pKd médio	Fármacos distintos	Proteínas distintas
Fold 0	30	21 (70,0%)	5,53	24	28
Fold 1	30	20 (66,7%)	5,48	23	29
Fold 2	30	23 (76,7%)	5,23	24	29
Fold 3	30	16 (53,3%)	5,84	23	30
Fold 4	30	18 (60,0%)	5,68	24	28
Total	**150**	**98 (65,3%)**	**5,55**		

Fonte: O autor (2026).

RELATÓRIO: TABELA 3

Tabela 3 – RMSE de cada método em cada fold, com as linhas de base

Fold	SSM-DTA	SubMDTA	Ensemble	Base: média do treino	Base: valor 5,0	Menor RMSE
Fold 0	0,636	0,943	0,739	0,957	1,092	SSM-DTA
Fold 1	0,731	1,307	0,912	0,959	1,068	SSM-DTA
Fold 2	0,577	0,473	0,415	0,595	0,491	Ensemble
Fold 3	1,251	1,420	1,273	1,234	1,450	SSM-DTA
Fold 4	1,186	1,488	1,293	1,029	1,222	SSM-DTA
Média	**0,876**	**1,126**	**0,926**	**0,955**	**1,065**	**SSM-DTA**
Desvio padrão	0,284	0,377	0,332			

Fonte: O autor (2026).

RELATÓRIO: TABELA 4

Tabela 4 – Melhor valor de cada métrica por método e partição em que ocorreu

Métrica (sentido do melhor)	**SSM-DTA**	**SubMDTA**	**Ensemble**
RMSE (menor)	0,577 (fold 2)	0,473 (fold 2)	0,415 (fold 2)
MAE (menor)	0,536 (fold 2)	0,369 (fold 2)	0,343 (fold 2)
Pearson (maior)	0,793 (fold 0)	0,527 (fold 2)	0,705 (fold 0)
Spearman (maior)	0,540 (fold 1)	0,543 (fold 2)	0,579 (fold 0)
CI (maior)	0,780 (fold 1)	0,835 (fold 2)	0,830 (fold 2)
R^2 (maior)	0,557 (fold 0)	0,028 (fold 0)	0,403 (fold 0)
Pior RMSE (para comparação)	1,251 (fold 3)	1,488 (fold 4)	1,293 (fold 4)

Fonte: O autor (2026).

8ª SIEPE SEMANA INTEGRADA ENSINO | PESQUISA | EXTENSÃO
EICTI XV Encontro Anual de Iniciação Científica e XI Encontro de Iniciação em Desenvolvimento Tecnológico e Inovação
UNILA

RELATÓRIO: TABELA 5

Tabela 5 – Métricas médias de cada método nas cinco partições (média ± desvio padrão amostral)

Métrica	SSM-DTA	SubMDTA	Ensemble
RMSE	0,876 ± 0,318	1,126 ± 0,421	0,926 ± 0,371
MAE	0,694 ± 0,211	0,878 ± 0,326	0,722 ± 0,257
Viés médio (predito − observado)	0,223 ± 0,182	0,126 ± 0,448	0,175 ± 0,269
Pearson	0,467 ± 0,281	0,282 ± 0,247	0,408 ± 0,267
Spearman	0,314 ± 0,221	0,282 ± 0,271	0,369 ± 0,209
CI	0,672 ± 0,119	0,650 ± 0,157	0,701 ± 0,132
R^2	−0,054 ± 0,543	−0,525 ± 0,484	−0,040 ± 0,381

Fonte: O autor (2026).

8ª SIEPE SEMANA INTEGRADA ENSINO | PESQUISA | EXTENSÃO
EICTI XV Encontro Anual de Iniciação Científica e XI Encontro de Iniciação em Desenvolvimento Tecnológico e Inovação
UNILA

RELATÓRIO: TABELA 6

Tabela 6 – Resultados dos testes pareados sobre o RMSE das cinco partições

Comparação	Diferença média	IC de 95%	t (gl = 4)	p (t)	W	p (Wilcoxon exato)	p (permutação)	d_z	g
SSM-DTA − SubMDTA	−0,250	[−0,556; 0,056]	−2,26	0,086	1	0,1250	0,1250	−1,01	−0,81
SSM-DTA − Ensemble	−0,050	[−0,213; 0,113]	−0,85	0,444	4	0,4375	0,4375	−0,38	−0,30
SubMDTA − Ensemble	0,200	[0,047; 0,353]	3,63	0,022	0	0,0625	0,0625	1,62	1,30

Fonte: O autor (2026).

RELATÓRIO: TABELA 7

Tabela 7 – Valores-p com correções para comparações múltiplas e para dependência entre partições

Comparação	p bruto (t)	p de Bonferroni	p de Holm	t corrigido (Nadeau e Bengio)	p corrigido
SSM-DTA − SubMDTA	0,086	0,259	0,172	−1,51	0,206
SSM-DTA − Ensemble	0,444	1,000	0,444	−0,57	0,602
SubMDTA − Ensemble	0,022	0,067	0,067	2,42	0,073

Fonte: O autor (2026).

RELATÓRIO: TABELA 8

Tabela 8 – Condição para que o ensemble supere o melhor dos dois métodos, por fold

Fold	Melhor método	MSE do SSM-DTA	MSE do SubMDTA	C (média de e_1e_2)	Limiar (Eq. 4)	MSE do ensemble	Ensemble supera o melhor?
Fold 0	SSM-DTA	0,405	0,889	0,446	0,163	0,546	Não
Fold 1	SSM-DTA	0,535	1,709	0,541	−0,053	0,831	Não
Fold 2	**SubMDTA**	**0,333**	**0,224**	**0,065**	**0,170**	**0,172**	**Sim**
Fold 3	SSM-DTA	1,564	2,017	1,448	1,337	1,619	Não
Fold 4	SSM-DTA	1,407	2,214	1,532	1,004	1,671	Não

Fonte: O autor (2026).

RELATÓRIO: TABELA 9

Tabela 9 – Desempenho nos pares com pKd = 5,0 e nos pares com afinidade medida (150 pares reunidos)

Método	RMSE (pKd = 5,0)	RMSE (medidos)	Viés (pKd = 5,0)	Viés (medidos)	Pearson (medidos)
SSM-DTA	0,769	1,154	0,613	−0,510	0,350
SubMDTA	1,021	1,451	0,517	−0,610	0,064
Ensemble	0,804	1,255	0,565	−0,560	0,217

Fonte: O autor (2026).

8ª SIEPE SEMANA INTEGRADA ENSINO | PESQUISA | EXTENSÃO
EICTI XV Encontro Anual de Iniciação Científica e XI Encontro de Iniciação em Desenvolvimento Tecnológico e Inovação
UNILA

RELATÓRIO: TABELA 10

Tabela 10 – RMSE nos pares cuja proteína aparece ou não no treino da mesma partição (150 pares reunidos)

Método	Proteína no treino (n = 50)	Proteína inédita (n = 100)	Razão (inédita / no treino)
SSM-DTA	0,720	1,007	1,40
SubMDTA	1,043	1,254	1,20
Ensemble	0,776	1,073	1,38

Fonte: O autor (2026).

8ª SIEPE SEMANA INTEGRADA ENSINO | PESQUISA | EXTENSÃO
EICTI XV Encontro Anual de Iniciação Científica e XI Encontro de Iniciação em Desenvolvimento Tecnológico e Inovação
UNILA

RELATÓRIO: TABELA 11

Tabela 11 – Conferência dos valores do resumo submetido

Valor	Resumo submetido	Este relatório
RMSE médio do SSM-DTA	0,876 ± 0,285	0,876 ± 0,284
RMSE médio do SubMDTA	1,126 ± 0,377	1,126 ± 0,377
RMSE médio do ensemble	0,926 ± 0,332	0,926 ± 0,332
SSM-DTA e SubMDTA: p (t); p (Wilcoxon); d	0,086; 0,125; −1,01	0,086; 0,125; −1,01
SSM-DTA e ensemble: p (t); p (Wilcoxon); d	0,444; 0,438; −0,38	0,444; 0,438; −0,38
SubMDTA e ensemble: p (t); p (Wilcoxon); d	0,022; 0,063; 1,62	0,022; 0,063; 1,62
Melhor RMSE do ensemble (fold 2)	0,415	0,415

Fonte: O autor (2026).

RELATÓRIO: TABELA 12

Tabela 12 – Métricas de cada método em cada fold (30 pares de teste por fold)

Fold	Método	RMSE	MAE	Pearson	Spearman	CI	R^2
Fold 0	SSM-DTA	0,636	0,546	0,793	0,512	0,778	0,557
	SubMDTA	0,943	0,743	0,526	0,441	0,738	0,028
	Ensemble	0,739	0,623	0,705	0,579	0,818	0,403
Fold 1	SSM-DTA	0,731	0,540	0,663	0,540	0,780	0,414
	SubMDTA	1,307	1,045	0,199	0,236	0,616	−0,875
	Ensemble	0,912	0,760	0,492	0,401	0,710	0,088
Fold 2	SSM-DTA	0,577	0,536	0,522	0,326	0,709	−0,752
	SubMDTA	0,473	0,369	0,527	0,543	0,835	−0,180
	Ensemble	0,415	0,343	0,577	0,515	0,830	0,095
Fold 3	SSM-DTA	1,251	0,925	0,156	0,021	0,524	−0,127
	SubMDTA	1,420	1,056	0,211	0,345	0,644	−0,453
	Ensemble	1,273	0,862	0,204	0,303	0,635	−0,167
Fold 4	SSM-DTA	1,186	0,925	0,201	0,172	0,571	−0,363
	SubMDTA	1,488	1,177	−0,053	−0,158	0,415	−1,144
	Ensemble	1,293	1,023	0,063	0,046	0,514	−0,618

Fonte: O autor (2026).

RELATÓRIO: TABELA 13 (FOLD 0)

Tabela 13 – Valores observados e preditos (pKd) nos 150 pares de teste: fold 0

Fold	Par	Observado	SSM-DTA	SubMDTA	Ensemble
Fold 0	1	5,00	5,53	6,32	5,92
	2	7,44	6,56	5,20	5,88
	3	5,00	6,07	6,30	6,18
	4	5,00	5,56	4,90	5,23
	5	5,51	6,07	6,19	6,13
	6	5,00	5,13	5,04	5,08
	7	8,55	7,68	6,60	7,14
	8	5,00	5,23	6,42	5,82
	9	5,00	5,48	5,18	5,33
	10	5,00	5,57	5,79	5,68
	11	5,00	5,14	5,22	5,18
	12	7,49	7,68	8,41	8,05
	13	5,00	5,56	5,48	5,52
	14	5,00	5,62	5,82	5,72
	15	5,00	5,33	5,73	5,53

Fold	Par	Observado	SSM-DTA	SubMDTA	Ensemble
	16	5,00	5,93	5,22	5,58
	17	5,00	6,31	5,81	6,06
	18	6,43	5,90	6,13	6,02
	19	5,00	5,37	5,11	5,24
	20	5,00	5,33	5,71	5,52
	21	5,80	5,54	5,65	5,59
	22	5,00	5,21	5,22	5,22
	23	5,00	5,42	5,35	5,38
	24	5,00	5,24	5,35	5,29
	25	6,92	5,48	5,56	5,52
	26	5,00	5,73	4,87	5,30
	27	5,68	5,28	6,66	5,97
	28	5,00	5,28	6,50	5,89
	29	6,96	7,68	8,38	8,03
	30	5,00	5,48	5,50	5,49

Fonte: O autor (2026).

RELATÓRIO: TABELA 13 (FOLD 1)

Tabela 13 – Valores observados e preditos (pKd) nos 150 pares de teste: fold 1

Fold	Par	Observado	SSM-DTA	SubMDTA	Ensemble
Fold 1	1	5,72	6,15	6,87	6,51
	2	5,00	5,22	5,36	5,29
	3	5,49	5,60	4,88	5,24
	4	7,27	5,62	6,68	6,15
	5	5,00	5,40	6,26	5,83
	6	5,00	4,97	8,14	6,55
	7	5,00	5,71	5,44	5,58
	8	6,57	6,27	6,61	6,44
	9	5,00	5,09	5,88	5,49
	10	5,00	5,63	4,97	5,30
	11	8,30	6,86	6,53	6,69
	12	5,00	5,35	5,51	5,43
	13	8,62	6,86	6,71	6,78
	14	5,40	6,89	6,65	6,77
	15	5,00	5,45	4,70	5,07
	16	5,00	5,57	5,55	5,56
	17	5,00	4,94	6,14	5,54
	18	5,00	5,45	4,71	5,08
	19	6,04	5,63	5,05	5,34
	20	5,00	5,57	6,40	5,98
	21	5,00	5,07	7,34	6,20
	22	5,00	5,23	5,43	5,33
	23	5,00	5,25	6,25	5,75
	24	5,00	5,20	5,67	5,43
	25	5,19	5,07	7,45	6,26
	26	5,00	5,24	7,27	6,26
	27	5,00	6,18	6,35	6,27
	28	5,00	5,24	5,17	5,21
	29	5,77	5,35	5,66	5,50
	30	5,00	6,16	6,88	6,52

Fonte: O autor (2026).

RELATÓRIO: TABELA 13 (FOLD 2)

Tabela 13 – Valores observados e preditos (pKd) nos 150 pares de teste: fold 2

Fold	Par	Observado	SSM-DTA	SubMDTA	Ensemble
Fold 2	1	5,62	5,60	5,68	5,64
	2	5,00	5,47	4,30	4,88
	3	5,00	5,63	4,99	5,31
	4	5,00	5,51	3,91	4,71
	5	5,00	5,86	5,42	5,64
	6	5,00	5,64	5,30	5,47
	7	5,00	5,56	4,73	5,14
	8	5,00	5,53	4,79	5,16
	9	5,00	6,04	5,17	5,61
	10	5,00	5,79	5,80	5,79
	11	5,00	5,55	5,06	5,31
	12	5,00	5,48	4,84	5,16
	13	5,00	5,60	4,75	5,18
	14	5,54	5,60	5,70	5,65
	15	5,00	5,55	4,92	5,24

Fold	Par	Observado	SSM-DTA	SubMDTA	Ensemble
	16	5,00	5,56	4,67	5,12
	17	5,00	5,47	4,27	4,87
	18	5,00	5,46	5,10	5,28
	19	5,00	5,93	5,90	5,91
	20	5,00	5,58	4,97	5,27
	21	6,34	6,75	6,01	6,38
	22	6,15	5,63	5,26	5,45
	23	6,23	6,07	6,17	6,12
	24	5,00	5,64	5,45	5,54
	25	5,00	5,64	5,54	5,59
	26	5,00	5,64	4,86	5,25
	27	5,77	5,48	5,10	5,29
	28	5,00	5,57	5,41	5,49
	29	6,16	5,72	5,60	5,66
	30	5,00	5,47	5,18	5,32

Fonte: O autor (2026).

RELATÓRIO: TABELA 13 (FOLD 3)

Tabela 13 – Valores observados e preditos (pKd) nos 150 pares de teste: fold 3

Fold	Par	Observado	SSM-DTA	SubMDTA	Ensemble
Fold 3	1	5,00	5,57	5,17	5,37
	2	5,00	5,94	5,47	5,71
	3	7,68	5,48	5,15	5,31
	4	5,00	5,25	4,53	4,89
	5	5,00	7,09	6,95	7,02
	6	5,92	5,29	5,21	5,25
	7	5,00	5,37	3,79	4,58
	8	5,27	6,43	6,97	6,70
	9	5,00	5,57	5,37	5,47
	10	5,00	6,11	5,30	5,70
	11	5,72	6,03	7,12	6,58
	12	7,11	5,29	4,42	4,86
	13	7,42	7,62	6,18	6,90
	14	8,60	5,35	5,40	5,37
	15	5,00	5,53	5,03	5,28

Fold	Par	Observado	SSM-DTA	SubMDTA	Ensemble
	16	5,00	5,39	4,74	5,07
	17	5,00	5,83	4,13	4,98
	18	7,40	7,76	6,69	7,23
	19	5,00	5,58	5,49	5,54
	20	5,00	5,56	5,17	5,37
	21	6,72	6,10	6,50	6,30
	22	5,00	5,38	3,90	4,64
	23	5,00	5,83	4,30	5,07
	24	5,00	5,51	4,46	4,98
	25	5,00	5,25	5,00	5,13
	26	8,77	5,35	5,17	5,26
	27	5,52	5,48	5,02	5,25
	28	7,24	5,47	5,15	5,31
	29	6,68	6,11	5,18	5,65
	30	5,28	5,92	5,77	5,84

Fonte: O autor (2026).

RELATÓRIO: TABELA 13 (FOLD 4)

Tabela 13 – Valores observados e preditos (pKd) nos 150 pares de teste: fold 4

Fold	Par	Observado	SSM-DTA	SubMDTA	Ensemble
Fold 4	1	5,00	7,27	8,89	8,08
	2	5,00	6,10	6,92	6,51
	3	5,00	5,44	4,59	5,02
	4	5,00	5,49	5,89	5,69
	5	5,00	5,46	5,75	5,60
	6	5,00	8,09	6,74	7,41
	7	5,37	5,54	6,18	5,86
	8	5,00	5,70	4,91	5,31
	9	7,48	6,87	5,42	6,15
	10	6,72	5,73	5,73	5,73
	11	5,00	5,38	5,19	5,28
	12	6,28	5,38	5,21	5,30
	13	7,55	7,69	8,16	7,93
	14	5,77	6,88	5,98	6,43
	15	6,00	5,73	5,67	5,70

Fold	Par	Observado	SSM-DTA	SubMDTA	Ensemble
	16	5,00	5,44	5,53	5,49
	17	6,09	5,43	4,56	4,99
	18	6,24	6,88	5,90	6,39
	19	5,00	5,88	6,39	6,13
	20	5,00	5,64	5,63	5,63
	21	5,00	5,62	6,06	5,84
	22	8,37	6,21	5,09	5,65
	23	6,34	5,43	5,03	5,23
	24	5,00	5,50	5,32	5,41
	25	8,15	5,65	6,62	6,14
	26	5,00	5,38	5,41	5,40
	27	5,00	5,72	6,57	6,15
	28	5,00	5,62	6,14	5,88
	29	5,00	7,34	7,92	7,63
	30	5,00	5,67	6,38	6,02

Fonte: O autor (2026).